Modelli statistici per dati Economici-Progetto

Giacomo Girardi

Analisi serie storiche multivariate

Idea

Nei laboratori visti a lezione, si sono utilizzati PIL, Investimenti e Consumi e sono state messe in relazione tra di loro tramite l'utilizzo di modelli VAR e VECM.

L'idea di base di questo docum ento è di utilizzare PIL e Investimenti e metterli in relazione con i tassi di interesse, sia a breve che a lungo termine, per un altro paese: la Spagna. Vogliamo quindi applicare i modelli visti in classi per capire le relazioni tra queste 4 variabili.

Dati e Introduzione

I dati scaricati da Eurostat sono serie storiche trimestali relative alla Spagna. Queste variabili riguardano:

- PIL ai prezzi di mercato
- Investimenti fissi lordi, indicatore macroeconomico che misura il valore dei nuovi beni capitali acquistati dalle imprese, dal governo e dalle famiglie
- tassi di rendimento dei titoli di stato a lungo termine
- tassi di rendimento dei titoli di stato a breve termine (3 mesi)

Per questi ultimi si hanno a disposizione i dati relativi all'area euro, non per i singoli paesi.

Avendo quindi a disposizione queste variabili possiamo fissarci degli obiettivi preliminari per la nostra analisi di serie storiche multivariate, in particolare:

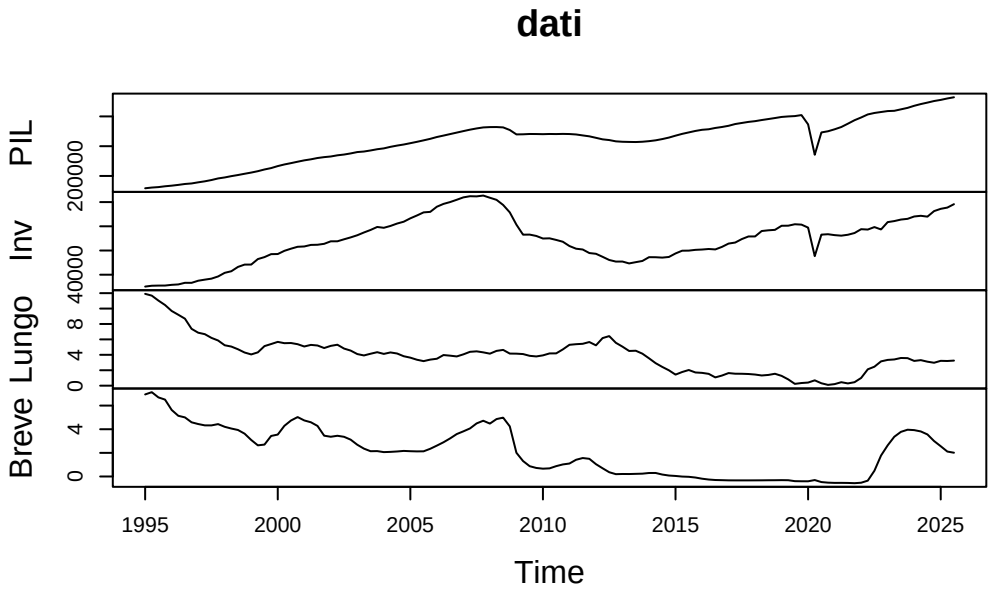
- identificare la causalità di Granger: riusciamo a prevedere le serie utilizzando i dati passati di altre?

- misurare come un aumento/o una diminuzione dei tassi influenzi investimenti e PIL, e come cambia nel tempo questo effetto
- analizzare se e come le previsioni migliorano in un ambito multivariato rispetto all'univariato

Le nostre analisi quindi si struttureranno nella seguente maniera:

- Analisi preliminari: ci permettono di capire come si comportano le singole serie, oltre a vedere un iniziale comportamento tra loro.
- Modelli VAR: permettono di effettuare analisi di causalità, decomposizione della varianza e IRF
- Cointegrazione: andremo ad analizzare se e come le serie si "muovono assieme nel tempo"
- Modelli a funzione di trasferimento: considereremo 2 serie tra le 3 totali per andare a studiare se e come una di esse può essere stimata in funzione dell'altra
- Analisi di previsione: confronteremo le previsioni ottenute con i vari approcci multivariati, anche rispetto all'univariato

```
#Iniziamo caricando i dati scaricati
library(readxl)
dati=read_excel("data/economici_dati.xlsx")
dati=ts(dati[, 2:5],start = c(1995, 1),frequency = 4)
colnames(dati)=c("PIL","Inv","Lungo","Breve")
plot.ts(dati)
```



```r
train=window(dati, end = c(2019, 4))
test=window(dati, start = c(2020, 1))

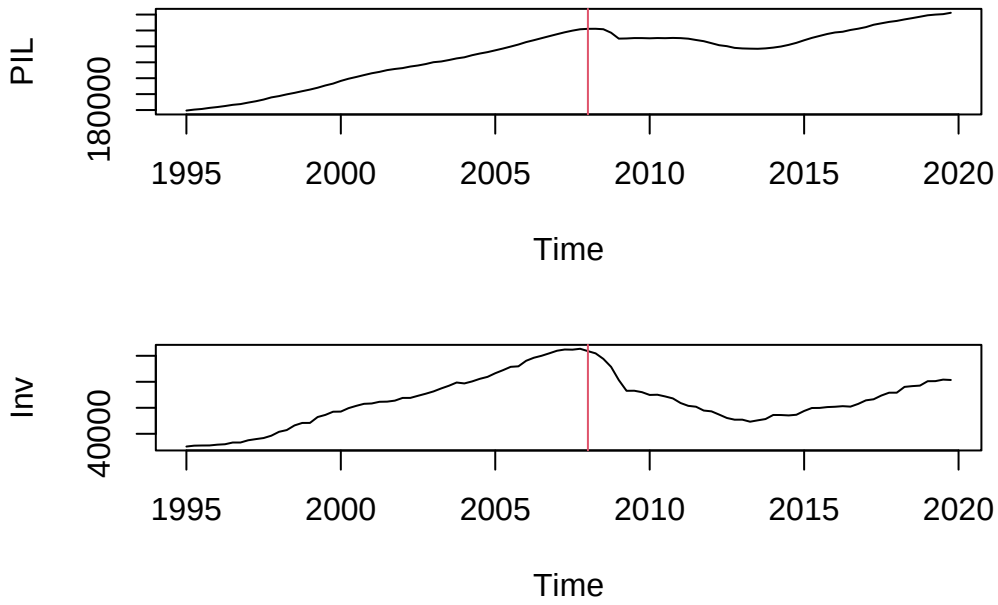
PIL=train[, "PIL"]
Inv=train[, "Inv"]
Lungo=train[, "Lungo"]
Breve=train[,"Breve"]
```

L'insieme delle 4 variabili è disponibile a partire dal primo trimestre 1995 fino all'ultimo del 2025, tuttavia, date le anomalie del periodo COVID per PIL, investimenti e tassi di interesse a breve termine si è deciso di selezionare i dati solo fino a prima del COVID come dataset di stima, e il resto come dataset di verifica per valutare le previsioni.

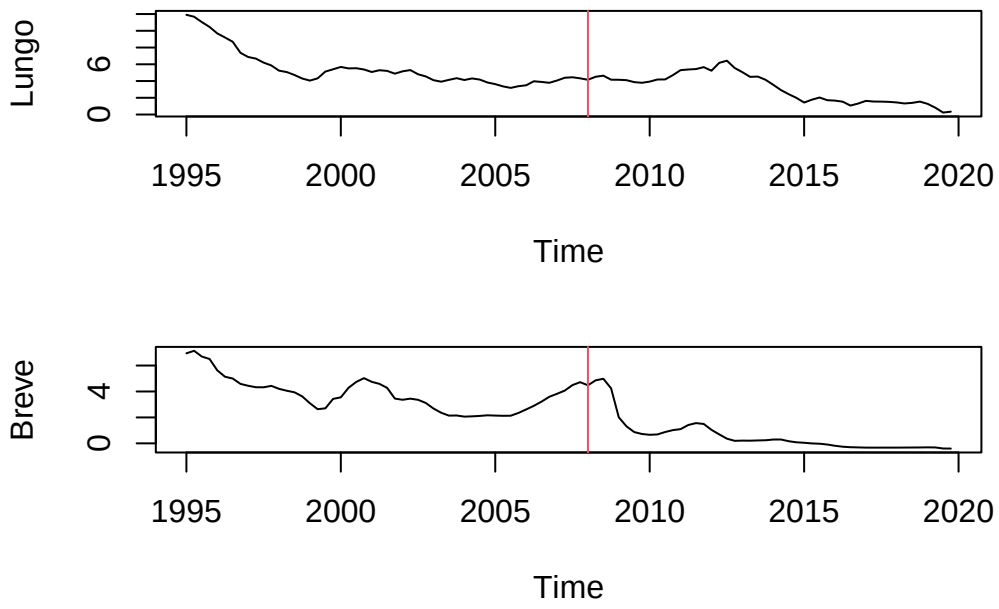
Analisi

Analisi preliminari

```r
par(mfrow=c(2,1))
par(mar = c(4, 4, 2, 2))
plot(PIL)
abline(v=2008,col=2)
plot(Inv)
abline(v=2008,col=2)
```



```
plot(Lungo)
abline(v=2008,col=2)
plot(Breve)
abline(v=2008,col=2)
```




```
# plot(log(l_gdp))
# abline(v=2008,col=2)
# plot(log(l_inv))
# abline(v=2008,col=2)
# plot(l_lungo)
# abline(v=2008,col=2)
```

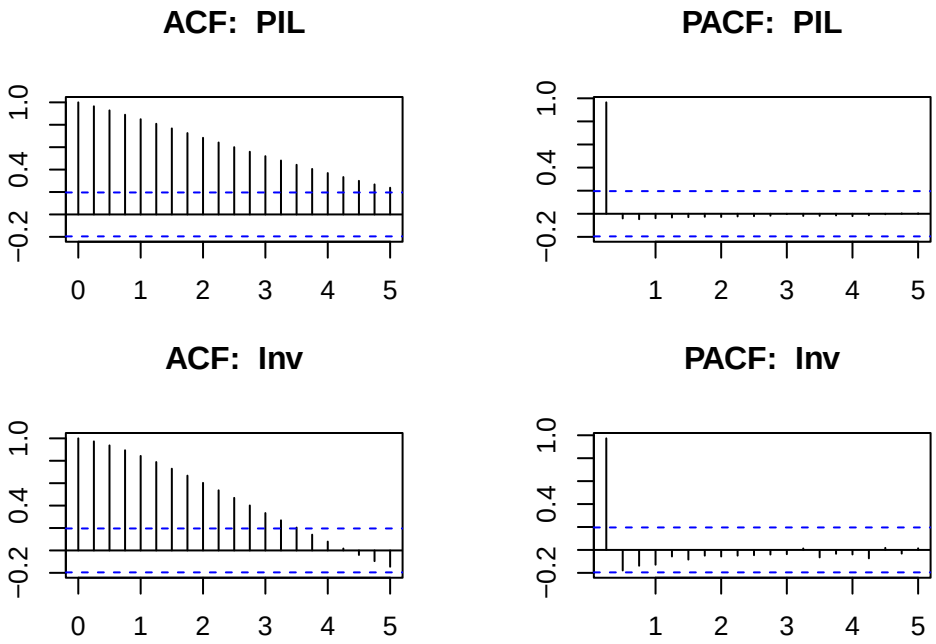
Iniziando con le analisi esplorative, vediamo:

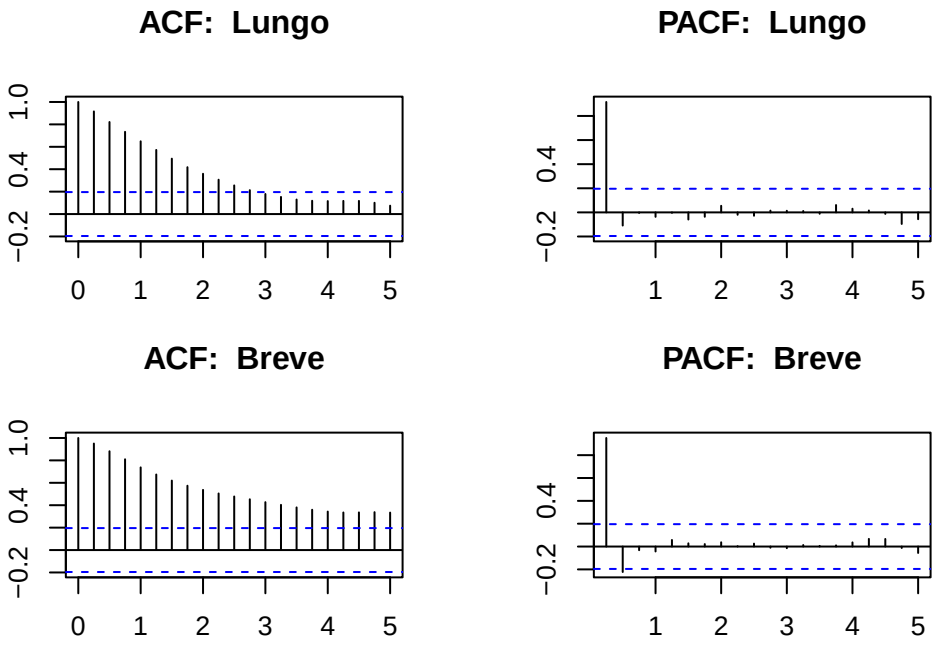
- per le prime 2 variabili un trend positivo: questo trend cala successivamente alla crisi del 2008 ma si vede come dopo qualche anno i valori inizino a risalire
- la terza variabile invece ha un leggero trend negativo, soprattutto negli ultimi anni, e non sembra essere toccata troppo dalla crisi del 2008.
- anche la quarta mostra un trend negativo, un po' più forte della precedente

Non sembra esserci stagionalità nelle variabili

Data la presenza di trend possiamo assumere che quindi le serie non sono stazionarie: per avere un'ulteriore conferma guardiamo ACF e PACF: in particolare, l'autocorrelogramma che si azzera lentamente è tipico delle serie non stazionarie.

```r
par(mfrow = c(2, 2))
par(mar = c(3, 3, 3, 3))
for(i in 1:NCOL(train)){
  acf(train[, i], main = paste("ACF: ",
                               colnames(train)[i]))
  pacf(train[, i], main = paste("PACF: ",
                                colnames(train)[i]))
}
```






```
par(mfrow = c(1, 1))
```

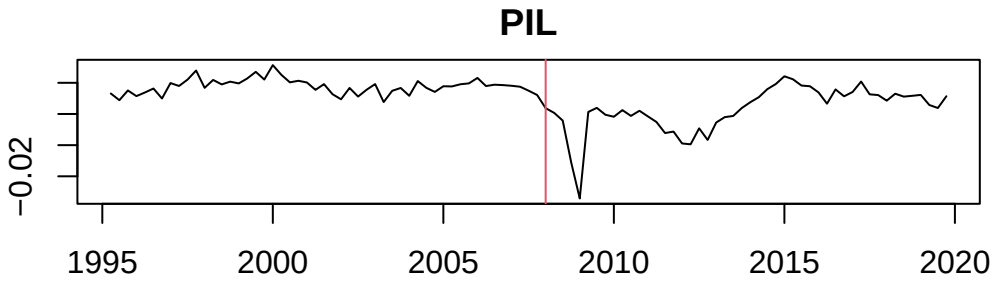
Decidiamo di differenziare i dati: tuttavia per PIL e Inv consideriamo la differenza logaritmica, che ci permette di analizzare quindi i tassi di variazione

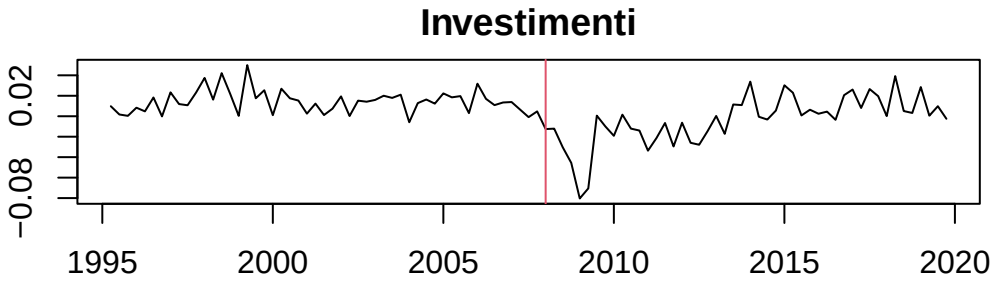
```
d_gdp=diff(log(train[,1]))
d_inv=diff(log(train[,2]))
d_lungo=diff(train[,3])
d_breve=diff(train[,4])


t_gdp=diff(log(test[,1]))
t_inv=diff(log(test[,2]))
t_lungo=diff(test[,3])
t_breve=diff(test[,4])
test_ok=cbind(t_gdp,t_inv,t_lungo,t_breve)

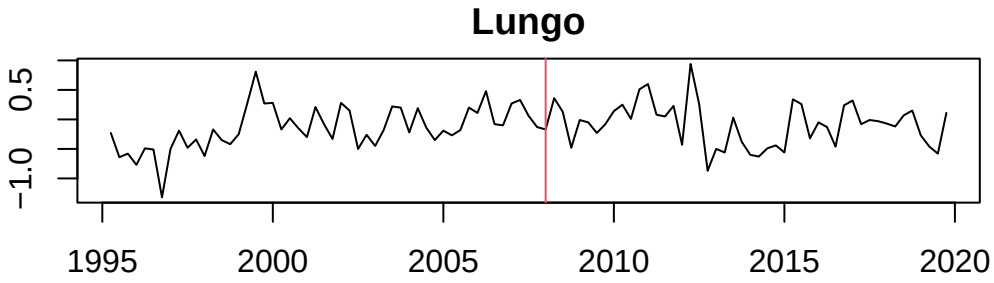
dati_ok=cbind(d_gdp, d_inv, d_lungo, d_breve)

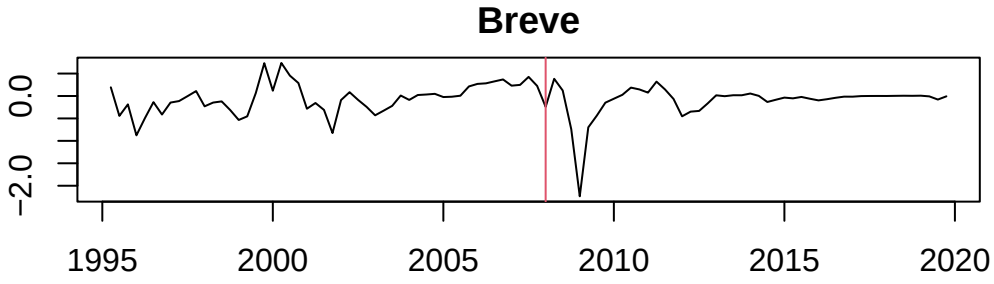
par(mar = c(3, 3, 2, 1))
par(mfrow = c(2, 1))
plot(dati_ok[,1], main="PIL"); abline(v=2008, col=2)
plot(dati_ok[,2], main="Investimenti"); abline(v=2008,
                                               col=2)
```






```
plot(dati_ok[,3], main="Lungo"); abline(v=2008, col=2)
plot(dati_ok[,4], main="Breve"); abline(v=2008, col=2)
```

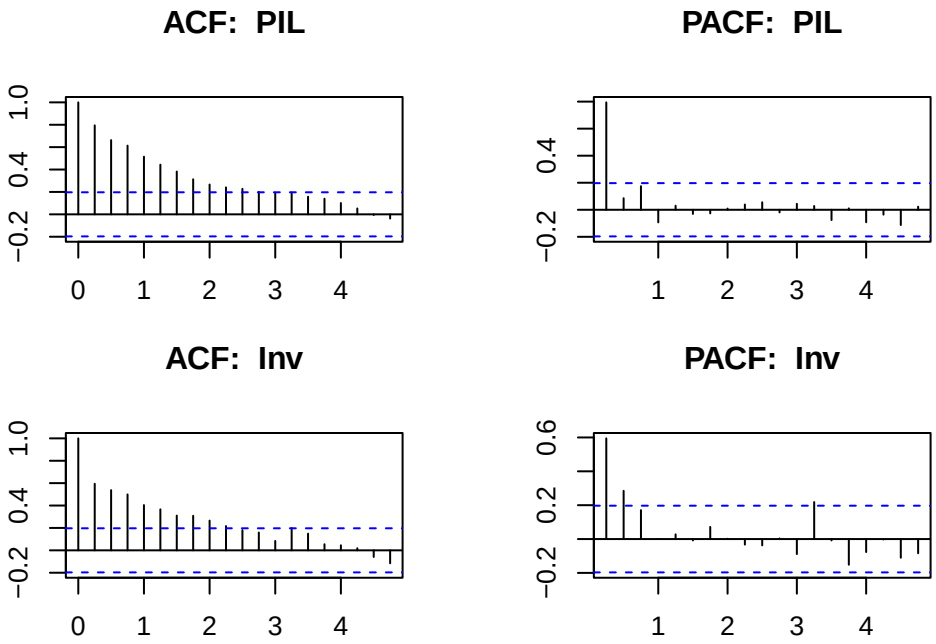


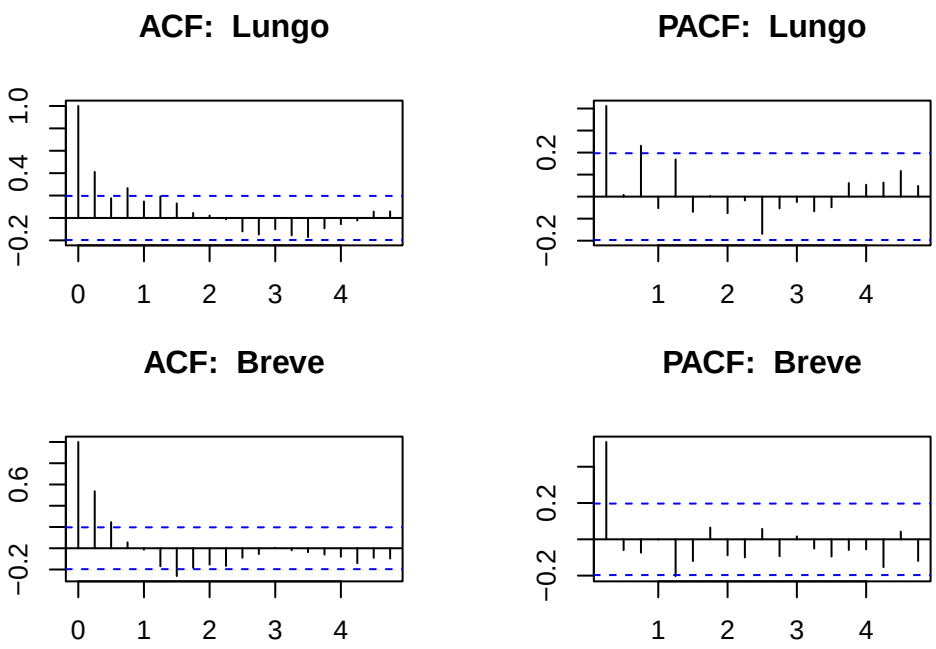



```
#top
```

Dai grafici (e dagli autocorrelogrammi) si nota la non stazionarietà delle serie; ora è inoltre più evidente lo shock che hanno avuto i dati nel 2008.

```
par(mfrow = c(2, 2))
par(mar = c(3, 3, 3, 3))
for(i in 1:NCOL(dati_ok)){
acf(dati_ok[,i], main = paste("ACF: ",
                              colnames(train)[i]))
pacf(dati_ok[,i], main = paste("PACF: ",
                              colnames(train)[i]))
}
```






```
par(mfrow = c(1, 1))
```

Per confermare la stazionarietà è tuttavia necessario fare un test ADF.

Test ADF

La procedura per il test ADF consiste nell'analizzare una serie alla volta e vedere l'ordine di cointegrazione. Procedura sequenziale:

- trend con costante
- solo costante (drift)
- senza trend deterministici

Iniziamo dal PIL

```
library(urca)
test_gdp_trend=ur.df(log(PIL), type="trend", lags=4,
                     selectlags = "BIC")
summary(test_gdp_trend)
```

```
###############################################
```

```
# Augmented Dickey-Fuller Test Unit Root Test #
###############################################

Test regression trend


Call:
lm(formula = z.diff ~ z.lag.1 + 1 + tt + z.diff.lag)

Residuals:
       Min         1Q     Median         3Q        Max
-0.0153568 -0.0016139  0.0004684  0.0020972  0.0206158

Coefficients:
             Estimate Std. Error t value Pr(>|t|)
(Intercept)  1.771e-01  8.154e-02   2.172   0.0325 *
z.lag.1     -1.431e-02  6.672e-03  -2.145   0.0346 *
tt           4.045e-05  3.194e-05   1.266   0.2086
z.diff.lag   7.525e-01  6.606e-02  11.391   <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.003933 on 91 degrees of freedom
Multiple R-squared:  0.6574,    Adjusted R-squared:  0.6461
F-statistic: 58.21 on 3 and 91 DF,  p-value: < 2.2e-16


Value of test-statistic is: -2.1447 3.4488 3.0404

Critical values for test statistics:
      1pct  5pct 10pct
tau3 -4.04 -3.45 -3.15
phi2  6.50  4.88  4.16
phi3  8.73  6.49  5.47
```

```r
#-2.1447 maggiore di -3.45, non rifiuto H0 di presenza di radice unitaria e non stazionarieta
#3.4488 minore di 4.88, non rifiuto H0 di assenza di trend e assenza drift
#3.0404 minore di 6.49, non rifiuto H0 di assenza di trend temporale

#rimuoviamo phi3
test_gdp_drift=ur.df(log(PIL), type="drift", lags=4,
                     selectlags = "BIC")
```

```r
summary(test_gdp_drift)
```

```
###############################################
# Augmented Dickey-Fuller Test Unit Root Test #
###############################################

Test regression drift


Call:
lm(formula = z.diff ~ z.lag.1 + 1 + z.diff.lag)

Residuals:
       Min         1Q     Median         3Q        Max
-0.0160754 -0.0017381  0.0004548  0.0017391  0.0200619

Coefficients:
             Estimate Std. Error t value Pr(>|t|)
(Intercept)  0.087829   0.041141   2.135   0.0354 *
z.lag.1     -0.006958   0.003299  -2.109   0.0377 *
z.diff.lag   0.745944   0.066071  11.290   <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.003946 on 92 degrees of freedom
Multiple R-squared:  0.6514,    Adjusted R-squared:  0.6438
F-statistic: 85.95 on 2 and 92 DF,  p-value: < 2.2e-16


Value of test-statistic is: -2.1091 4.343

Critical values for test statistics:
      1pct  5pct 10pct
tau2 -3.51 -2.89 -2.58
phi1  6.70  4.71  3.86
```

```r
#-1.5832 maggiore di -2.89 non rifiuto H0 di presenza di radice unitaria e non stazionarietà
#3.4775 minore di 4.71 non rifiuto assenza di drift
#no drift, no trend, però non stazionaria
```

```r
test_gdp_diff=ur.df(diff(log(PIL)),lags=4,
                    selectlags = "BIC")
summary(test_gdp_diff)
```

```
###############################################
# Augmented Dickey-Fuller Test Unit Root Test #
###############################################

Test regression none


Call:
lm(formula = z.diff ~ z.lag.1 - 1 + z.diff.lag)

Residuals:
       Min         1Q     Median         3Q        Max
-0.0148056 -0.0012946  0.0007011  0.0024993  0.0233904

Coefficients:
           Estimate Std. Error t value Pr(>|t|)
z.lag.1    -0.11182    0.05165  -2.165    0.033 *
z.diff.lag -0.11694    0.10374  -1.127    0.263
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.004095 on 92 degrees of freedom
Multiple R-squared:  0.07636,   Adjusted R-squared:  0.05628
F-statistic: 3.803 on 2 and 92 DF,  p-value: 0.02589


Value of test-statistic is: -2.1648

Critical values for test statistics:
     1pct  5pct 10pct
tau1 -2.6 -1.95 -1.61
```

```r
#minore, rifiuto presenza di radice unitaria
#pero solo a 0.05
#rifiuto non stazionarietà, differenza prima stazionaria, ok
```

```
#gpd I(1) senza drift e trend
```

Possiamo concludere che la serie del PIL sia I(1), e che la sua differenza prima sia I(0). Passiamo agli investimenti:

```
test_inv_trend=ur.df(log(Inv), type="trend", lags=4,
                     selectlags = "BIC")
summary(test_inv_trend)
```

```
###############################################
# Augmented Dickey-Fuller Test Unit Root Test #
###############################################

Test regression trend


Call:
lm(formula = z.diff ~ z.lag.1 + 1 + tt + z.diff.lag)

Residuals:
      Min        1Q    Median        3Q       Max
-0.050591 -0.009788  0.001087  0.008694  0.051547

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  2.324e-01  1.069e-01   2.175 0.032232 *
z.lag.1     -2.115e-02  9.908e-03  -2.134 0.035546 *
tt          -1.477e-05  6.464e-05  -0.229 0.819739
z.diff.lag1  3.960e-01  9.939e-02   3.984 0.000137 ***
z.diff.lag2  2.887e-01  9.909e-02   2.914 0.004507 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.01601 on 90 degrees of freedom
Multiple R-squared:  0.4413,    Adjusted R-squared:  0.4165
F-statistic: 17.77 on 4 and 90 DF,  p-value: 8.747e-11


Value of test-statistic is: -2.1342 2.0551 2.6763
```

```
Critical values for test statistics:
      1pct  5pct 10pct
tau3 -4.04 -3.45 -3.15
phi2  6.50  4.88  4.16
phi3  8.73  6.49  5.47
```

```r
#-2.1342 maggiore di -3.45, non rifiuto H0 di non staz
#2.0551 minore di 4.88 non rifiuto H0 di assenza di trend e assenza drift
#2.6763 minore di 6.49 non rifiuto H0 di assenza di trend temporale

test_inv_drift=ur.df(log(Inv), type="drift", lags=4,
                     selectlags = "BIC")
summary(test_inv_drift)
```

```
###############################################
# Augmented Dickey-Fuller Test Unit Root Test #
###############################################

Test regression drift


Call:
lm(formula = z.diff ~ z.lag.1 + 1 + z.diff.lag)

Residuals:
      Min        1Q    Median        3Q       Max
-0.050310 -0.010096  0.001440  0.008865  0.051885

Coefficients:
             Estimate Std. Error t value Pr(>|t|)
(Intercept)  0.238862   0.102556   2.329 0.022068 *
z.lag.1     -0.021810   0.009424  -2.314 0.022901 *
z.diff.lag1  0.397833   0.098548   4.037 0.000113 ***
z.diff.lag2  0.291536   0.097804   2.981 0.003687 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.01593 on 91 degrees of freedom
Multiple R-squared:  0.441, Adjusted R-squared:  0.4226
F-statistic: 23.93 on 3 and 91 DF,  p-value: 1.662e-11
```

```
Value of test-statistic is: -2.3143 3.0887

Critical values for test statistics:
      1pct  5pct 10pct
tau2 -3.51 -2.89 -2.58
phi1  6.70  4.71  3.86
```

```r
#-2.3143 maggiore di -2.89, non rifiuto la non stazionarietà
#3.0887 minore di 4.71, accetto assenza di drift

test_inv_diff=ur.df(diff(log(Inv)),lags=4,
                    selectlags = "BIC")
summary(test_inv_diff)
```

```
###############################################
# Augmented Dickey-Fuller Test Unit Root Test #
###############################################

Test regression none


Call:
lm(formula = z.diff ~ z.lag.1 - 1 + z.diff.lag)

Residuals:
      Min        1Q    Median        3Q       Max
-0.051410 -0.009570  0.001962  0.010902  0.055341

Coefficients:
           Estimate Std. Error t value Pr(>|t|)
z.lag.1    -0.26533    0.08638  -3.072  0.00280 **
z.diff.lag -0.29689    0.09974  -2.977  0.00372 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.01637 on 92 degrees of freedom
Multiple R-squared:  0.2598,    Adjusted R-squared:  0.2437
F-statistic: 16.14 on 2 and 92 DF,  p-value: 9.795e-07
```

```
Value of test-statistic is: -3.0718

Critical values for test statistics:
     1pct  5pct 10pct
tau1 -2.6 -1.95 -1.61
```

```
#minore, rifiuto ipotesi di non stazionarietà
#serie è I(1)
```

Stessa identica cosa per quanto riguarda gli investimenti. Analizziamo i tassi, iniziando da quelli a lungo termine.

```
test_lungo_trend=ur.df(Lungo, type="trend", lags=4,
                       selectlags = "BIC")
summary(test_lungo_trend)
```

```
###############################################
# Augmented Dickey-Fuller Test Unit Root Test #
###############################################

Test regression trend


Call:
lm(formula = z.diff ~ z.lag.1 + 1 + tt + z.diff.lag)

Residuals:
     Min       1Q   Median       3Q      Max
-0.85004 -0.21920 -0.00875  0.20767  1.31079

Coefficients:
             Estimate Std. Error t value Pr(>|t|)
(Intercept)  0.466093   0.207896   2.242  0.02739 *
z.lag.1     -0.082919   0.028861  -2.873  0.00506 **
tt          -0.003511   0.001898  -1.850  0.06755 .
z.diff.lag   0.374335   0.091577   4.088 9.38e-05 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.3231 on 91 degrees of freedom
Multiple R-squared:  0.2227,    Adjusted R-squared:  0.1971
```

```
F-statistic: 8.692 on 3 and 91 DF,  p-value: 3.942e-05


Value of test-statistic is: -2.873 3.7731 4.2795

Critical values for test statistics:
      1pct  5pct 10pct
tau3 -4.04 -3.45 -3.15
phi2  6.50  4.88  4.16
phi3  8.73  6.49  5.47
```

```r
#-2.873 maggiore di -3.45, non rifiuto H0 di presenza di radice unitaria e non stazionarietà
#3.7731 minore di 4.88 non rifiuto H0 di assenza di trend e assenza drift
#4.2795  minore di 6.49 non rifiuto H0 di assenza di trend temporale

test_lungo_drift=ur.df(Lungo, type="drift", lags=4,
                       selectlags = "BIC")
summary(test_lungo_drift)
```

```
###############################################
# Augmented Dickey-Fuller Test Unit Root Test #
###############################################

Test regression drift


Call:
lm(formula = z.diff ~ z.lag.1 + 1 + z.diff.lag)

Residuals:
     Min       1Q   Median       3Q      Max
-0.88429 -0.20462 -0.01962  0.18999  1.20160

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  0.11340    0.08401   1.350 0.180389
z.lag.1     -0.04196    0.01875  -2.237 0.027697 *
z.diff.lag   0.36179    0.09252   3.910 0.000176 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Residual standard error: 0.3273 on 92 degrees of freedom
Multiple R-squared:  0.1935,    Adjusted R-squared:  0.176
F-statistic: 11.04 on 2 and 92 DF,  p-value: 5.061e-05


Value of test-statistic is: -2.2371 3.8471

Critical values for test statistics:
      1pct  5pct 10pct
tau2 -3.51 -2.89 -2.58
phi1  6.70  4.71  3.86
```

```r
#-2.2371 maggiore di -2.89, non rifiuto la non stazionarietà
#3.8471 minore di 4.71, accetto assenza di drift

test_lungo_diff=ur.df(diff(Lungo),lags=4,
                      selectlags = "BIC")
summary(test_lungo_diff)
```

```
###############################################
# Augmented Dickey-Fuller Test Unit Root Test #
###############################################

Test regression none


Call:
lm(formula = z.diff ~ z.lag.1 - 1 + z.diff.lag)

Residuals:
     Min       1Q   Median       3Q      Max
-0.96222 -0.23567 -0.06044  0.16806  1.12020

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
z.lag.1      -0.4363     0.1193  -3.656 0.000428 ***
z.diff.lag1  -0.1659     0.1153  -1.439 0.153585
z.diff.lag2  -0.2628     0.1006  -2.614 0.010486 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Residual standard error: 0.33 on 91 degrees of freedom
Multiple R-squared:  0.3468,    Adjusted R-squared:  0.3252
F-statistic:  16.1 on 3 and 91 DF,  p-value: 1.774e-08


Value of test-statistic is: -3.6564

Critical values for test statistics:
     1pct  5pct 10pct
tau1 -2.6 -1.95 -1.61
```

```r
#minore, rifiuto ipotesi di non stazionarietà
```

Anche per quanto riguarda i tassi di interesse, la serie è I(1), mentre le differenze prime sono I(0). Vediamo per i tassi di interesse a breve termine:

```r
test_breve_trend=ur.df(Breve, type="trend", lags=4,
                       selectlags = "BIC")
summary(test_breve_trend)
```

```
###############################################
# Augmented Dickey-Fuller Test Unit Root Test #
###############################################

Test regression trend


Call:
lm(formula = z.diff ~ z.lag.1 + 1 + tt + z.diff.lag)

Residuals:
     Min       1Q   Median       3Q      Max
-1.50399 -0.06813 -0.01747  0.09827  0.82725

Coefficients:
             Estimate Std. Error t value Pr(>|t|)
(Intercept)  0.583862   0.178971   3.262 0.001557 **
z.lag.1     -0.115933   0.031919  -3.632 0.000465 ***
tt          -0.006908   0.002177  -3.173 0.002055 **
z.diff.lag   0.590818   0.080442   7.345 8.51e-11 ***
```

```
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.2749 on 91 degrees of freedom
Multiple R-squared:  0.3994,    Adjusted R-squared:  0.3796
F-statistic: 20.17 on 3 and 91 DF,  p-value: 4.158e-10


Value of test-statistic is: -3.6321 4.6302 6.5973

Critical values for test statistics:
      1pct  5pct 10pct
tau3 -4.04 -3.45 -3.15
phi2  6.50  4.88  4.16
phi3  8.73  6.49  5.47
```

```r
#-3.6321 minore di -3.45, rifiuto H0 di non staz
#4.6302 minore di 4.88 non rifiuto H0 di assenza di trend e assenza drift
#6.5973 maggiore di 6.49 rifiuto H0 di assenza di trend temporale
#c'è trend temporale

test_breve_diff=ur.df(diff(Breve),lags=4,
                      selectlags = "BIC")
summary(test_breve_diff)
```

```
###############################################
# Augmented Dickey-Fuller Test Unit Root Test #
###############################################

Test regression none


Call:
lm(formula = z.diff ~ z.lag.1 - 1 + z.diff.lag)

Residuals:
     Min       1Q   Median       3Q      Max
-1.77170 -0.07671  0.00274  0.05285  0.73254

Coefficients:
           Estimate Std. Error t value Pr(>|t|)
```

```
z.lag.1    -0.48179    0.09429  -5.110 1.74e-06 ***
z.diff.lag  0.09376    0.10059   0.932    0.354
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.2921 on 92 degrees of freedom
Multiple R-squared:  0.2343,    Adjusted R-squared:  0.2177
F-statistic: 14.08 on 2 and 92 DF,  p-value: 4.641e-06


Value of test-statistic is: -5.1098

Critical values for test statistics:
     1pct  5pct 10pct
tau1 -2.6 -1.95 -1.61
```

```
#minore, rifiuto ipotesi di non stazionarietà
```

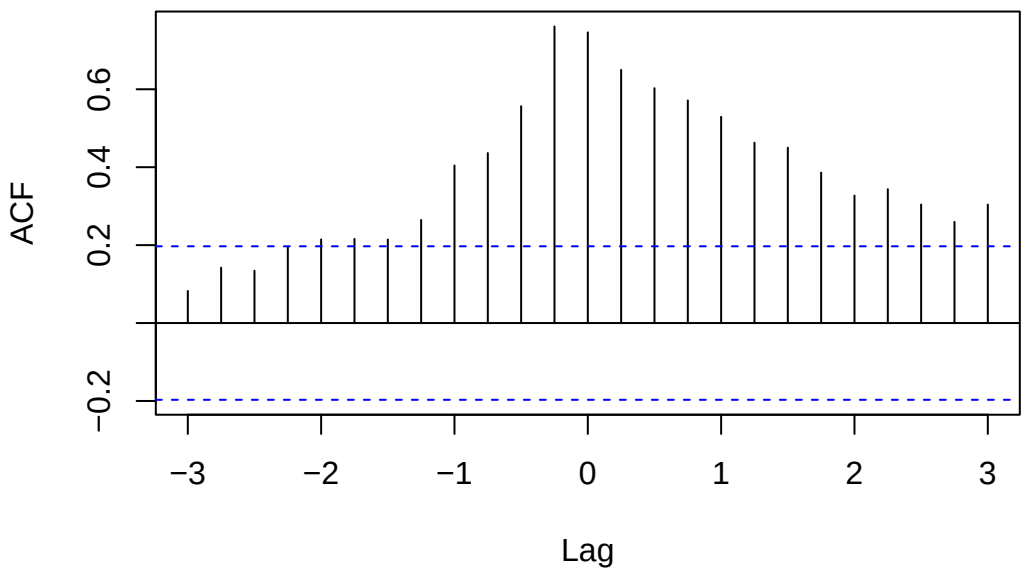
Questa serie è stazionaria attorno ad un trend, sarebbe quindi I(0) ma è prassi considerarli I(1) nel VECM per omogeneità all'interno del sistema. In ogni caso la serie in differenze prime è stazionaria.

CCF

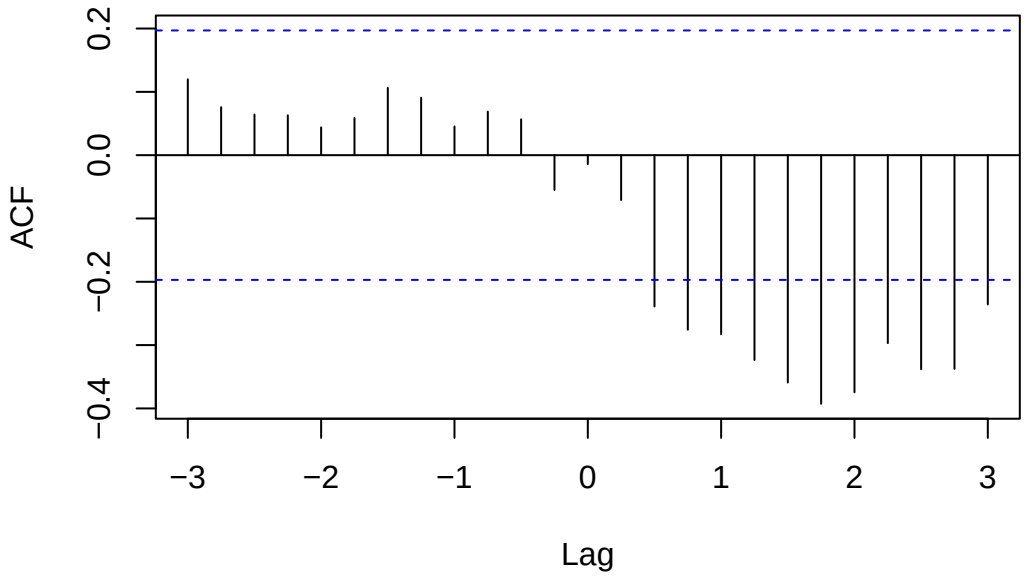
Ora, prima di fare qualsiasi altra analisi multivariata, andiamo ad analizzare la funzione di cross-correlazione, in modo da poter capire quali sono le relazioni che ci aspettiamo tra variabili.

```
# 2. Imposta la griglia 3x2 e riduci i margini per far stare tutto
par(mfrow = c(1, 1), mar = c(4, 4, 3, 1))

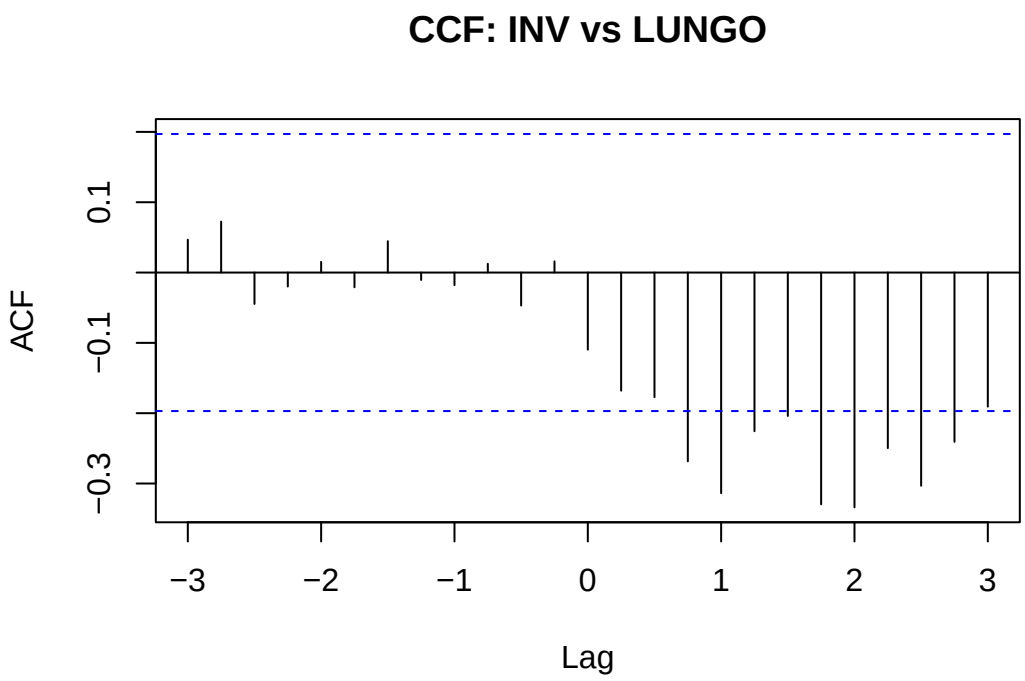
# 3. Calcolo delle 6 CCF
# Relazioni con il PIL
ccf(dati_ok[,1], dati_ok[,2], main = "CCF: GDP vs INV",
    lag.max = 12)
```



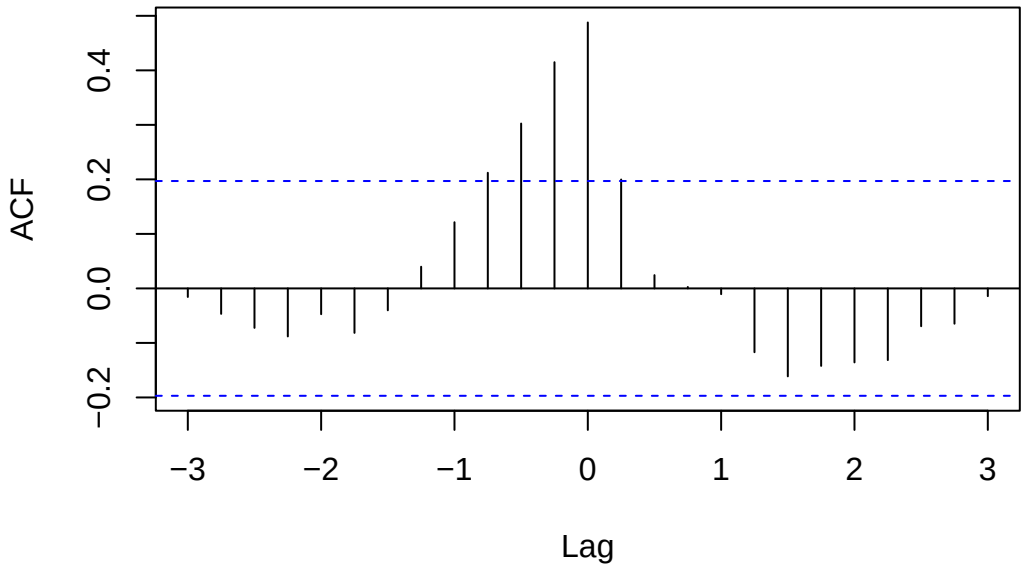

```
ccf(dati_ok[,1], dati_ok[,3], main = "CCF: GDP vs LUNGO",
    lag.max = 12)
```



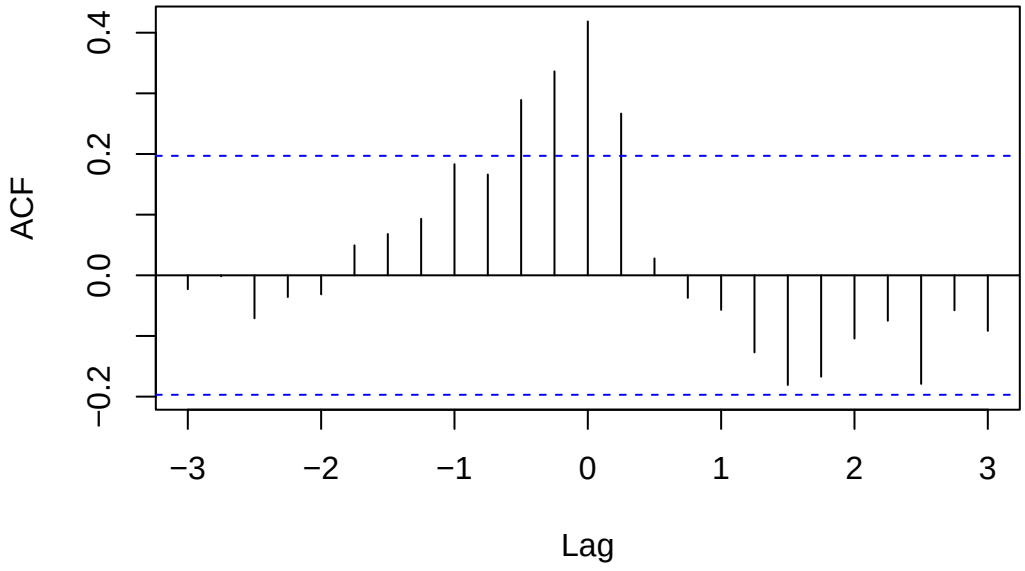
```r
# Relazioni con gli Investimenti
ccf(dati_ok[,2], dati_ok[,3], main = "CCF: INV vs LUNGO",
    lag.max = 12)
```



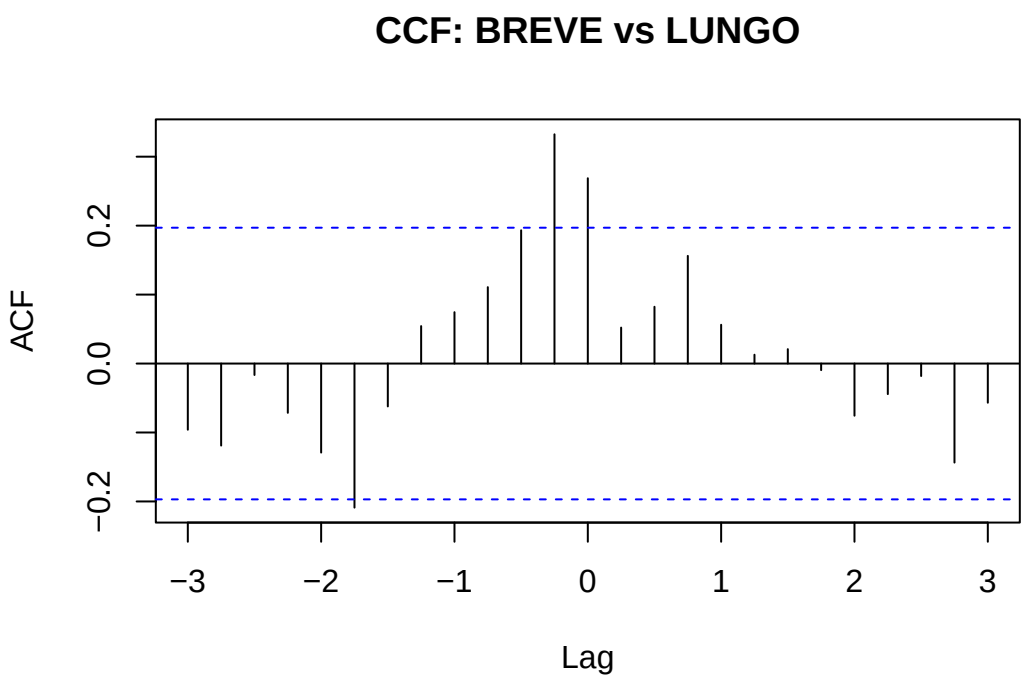

```r
ccf(dati_ok[,1], dati_ok[,4], main = "CCF: GDP vs BREVE",
    lag.max = 12)
```




```
ccf(dati_ok[,2], dati_ok[,4], main = "CCF: INV vs BREVE",
    lag.max = 12)
```



```r
ccf(dati_ok[,3], dati_ok[,4], main = "CCF: BREVE vs LUNGO",
    lag.max = 12)
```




```r
# 4. Ripristina i parametri grafici di default
par(mfrow = c(1, 1))
```

Notiamo le seguenti relazioni:

- relazione biunivoca tra PIL e investimenti, i valori futuri di una dipendono da quelli passati dell'altra, e viceversa;
- valori passati dei tassi di interesse a lungo termine hanno effetto su quelli futuri sia di PIL che di investimenti;
- relazione biunivoca PIL-breve e inv-breve: PIL e investimenti del passato hanno effetto sui tassi a breve termine nel futuro;
- breve del passato sembra avere effetto sul lungo del passato;

Da considerare che però, per avere i veri valori delle CCF i dati dovrebbero essere prima sbiancati tramite un modello ARIMA, in modo da eliminare le autocorrelazioni dentro le singole serie. Possiamo capire però che i modelli per serie storiche multivariate sono quelli adeguati.

Modello VAR(1)

Ora, prima di passare ad'analisi di cointegrazione, stimiamo un modello VAR ed effettuiamo le analisi relative ad esso.

```
library(vars)
```

```
Caricamento del pacchetto richiesto: MASS
```

```
Caricamento del pacchetto richiesto: strucchange
```

```
Caricamento del pacchetto richiesto: zoo
```

```

Caricamento pacchetto: 'zoo'
```

```
I seguenti oggetti sono mascherati da 'package:base':
```

```
    as.Date, as.Date.numeric
```

```
Caricamento del pacchetto richiesto: sandwich
```

```
Caricamento del pacchetto richiesto: lmtest
```

```
ICsel=VARselect(dati_ok, lag.max = 4, type = "const")
ICsel$selection
```

```
AIC(n)  HQ(n)  SC(n) FPE(n)
     1      1      1      1
```

Per prima cosa usiamo i criteri di informazione per selezionare il numero di lag p ottimale: tutti selezionano p=1.

```
mod1=vars::VAR(dati_ok, p = 1, type = "const")
summary(mod1)
```

```
VAR Estimation Results:
========================
Endogenous variables: d_gdp, d_inv, d_lungo, d_breve
Deterministic variables: const
Sample size: 98
Log Likelihood: 683.631
Roots of the characteristic polynomial:
0.8083 0.4164 0.4164 0.004859
Call:
vars::VAR(y = dati_ok, p = 1, type = "const")


Estimation results for equation d_gdp:
======================================
d_gdp = d_gdp.l1 + d_inv.l1 + d_lungo.l1 + d_breve.l1 + const

             Estimate Std. Error t value Pr(>|t|)
d_gdp.l1    0.8006681  0.0906707   8.831 6.09e-14 ***
d_inv.l1    0.0532821  0.0280113   1.902 0.060244 .
d_lungo.l1  0.0005514  0.0010959   0.503 0.616041
d_breve.l1 -0.0049343  0.0012881  -3.831 0.000232 ***
const       0.0004383  0.0005760   0.761 0.448556
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1


Residual standard error: 0.003703 on 93 degrees of freedom
Multiple R-Squared: 0.6901, Adjusted R-squared: 0.6768
F-statistic: 51.77 on 4 and 93 DF,  p-value: < 2.2e-16


Estimation results for equation d_inv:
======================================
d_inv = d_gdp.l1 + d_inv.l1 + d_lungo.l1 + d_breve.l1 + const

            Estimate Std. Error t value Pr(>|t|)
d_gdp.l1    2.449244   0.322190   7.602 2.28e-11 ***
d_inv.l1    0.044374   0.099535   0.446   0.6568
d_lungo.l1 -0.007124   0.003894  -1.829   0.0706 .
d_breve.l1 -0.005492   0.004577  -1.200   0.2332
const      -0.008925   0.002047  -4.361 3.34e-05 ***
---
```

```
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1


Residual standard error: 0.01316 on 93 degrees of freedom
Multiple R-Squared: 0.6107, Adjusted R-squared: 0.594
F-statistic: 36.48 on 4 and 93 DF,  p-value: < 2.2e-16


Estimation results for equation d_lungo:
========================================
d_lungo = d_gdp.l1 + d_inv.l1 + d_lungo.l1 + d_breve.l1 + const

            Estimate Std. Error t value Pr(>|t|)
d_gdp.l1   -10.64336    8.25064  -1.290   0.2002
d_inv.l1     4.25794    2.54891   1.670   0.0982 .
d_lungo.l1   0.45714    0.09973   4.584 1.42e-05 ***
d_breve.l1  -0.08117    0.11721  -0.693   0.4903
const       -0.03514    0.05241  -0.670   0.5043
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1


Residual standard error: 0.3369 on 93 degrees of freedom
Multiple R-Squared: 0.1983, Adjusted R-squared: 0.1639
F-statistic: 5.752 on 4 and 93 DF,  p-value: 0.0003509


Estimation results for equation d_breve:
========================================
d_breve = d_gdp.l1 + d_inv.l1 + d_lungo.l1 + d_breve.l1 + const

           Estimate Std. Error t value Pr(>|t|)
d_gdp.l1   10.81509    7.02019   1.541 0.126818
d_inv.l1    1.24938    2.16878   0.576 0.565956
d_lungo.l1  0.24408    0.08485   2.877 0.004986 **
d_breve.l1  0.34228    0.09973   3.432 0.000896 ***
const      -0.08621    0.04459  -1.933 0.056244 .
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1


Residual standard error: 0.2867 on 93 degrees of freedom
Multiple R-Squared: 0.3761, Adjusted R-squared: 0.3493
```

```
F-statistic: 14.02 on 4 and 93 DF,  p-value: 5.492e-09



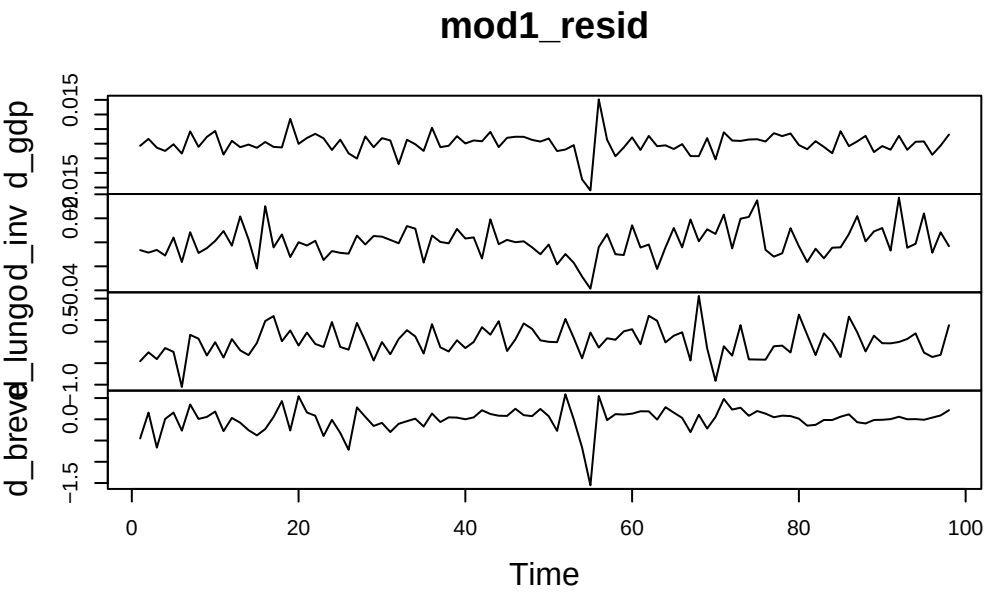
Covariance matrix of residuals:
            d_gdp      d_inv    d_lungo   d_breve
d_gdp   1.371e-05  1.585e-05  7.282e-05 0.0005611
d_inv   1.585e-05  1.731e-04 -7.958e-05 0.0013405
d_lungo 7.282e-05 -7.958e-05  1.135e-01 0.0218109
d_breve 5.611e-04  1.341e-03  2.181e-02 0.0821906

Correlation matrix of residuals:
          d_gdp    d_inv  d_lungo d_breve
d_gdp   1.00000  0.32536  0.05837  0.5286
d_inv   0.32536  1.00000 -0.01795  0.3554
d_lungo 0.05837 -0.01795  1.00000  0.2258
d_breve 0.52860  0.35538  0.22579  1.0000
```

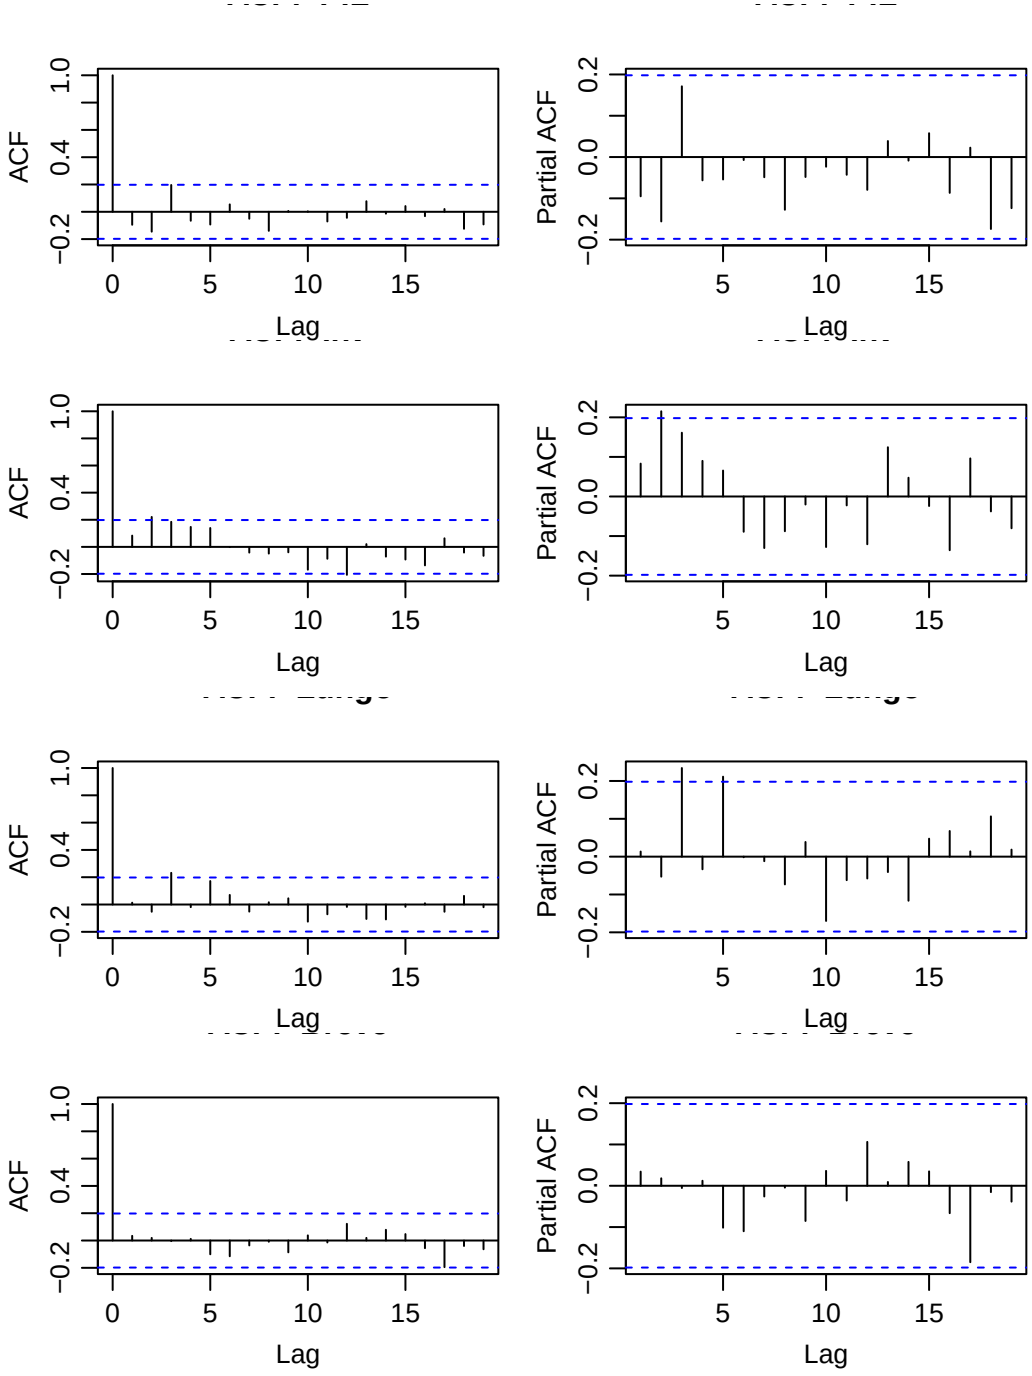
Coefficienti e relazioni tra variabili:

- **PIL**: nell'equazione del PIL i valori passati del PIL risultano significativi, significa che valori passati di investimenti e tassi non sembrano avere alcun effetto. Anche i valori passati dei tassi brevi hanno effetto negativo signifcativo
- **Investimenti:** PIL e tassi a lungo termine hanno effetto significativo (i secondi è debolmente significativo l'effetto), rispettivamente positivo e negativo. Gli investimenti non sembrano essere invece influenzati dai valori passati di sè stessi.
- **Tassi a lungo**: come rispetto al PIL: i valori passati della serie stessa hanno effetto negativo significativo. Anche gli investimenti sembrano avere leggero effetto negativo
- **Tassi brevi**: entrambi i tassi hanno effetto positivo significativo

```
mod1_resid=resid(mod1)
plot.ts(mod1_resid)
```




```
par(mfrow = c(2, 2), mar = c(3, 3, 2, 1),
    mgp = c(2, 0.7, 0))
for(i in 1:NCOL(mod1_resid)){
  acf(mod1_resid[,i], main = paste("ACF: ",
                                   colnames(train)[i]))
  pacf(mod1_resid[,i], main = paste("ACF: ",
                                   colnames(train)[i]))
}
```




```
par(mfrow = c(1, 1))
# Matrice di correlazione
cor(mod1_resid)
```

```
             d_gdp       d_inv     d_lungo   d_breve
d_gdp   1.00000000  0.32535687  0.05836556 0.5285997
d_inv   0.32535687  1.00000000 -0.01795168 0.3553798
d_lungo 0.05836556 -0.01795168  1.00000000 0.2257941
d_breve 0.52859973  0.35537984  0.22579412 1.0000000
```

Guardando gli autocorrelogrami dei residui, non sembrerebbe esserci autocorrelazione non spiegata dal modello, il che è un segnale positivo, dato che la correlazione non supera le bande di significatività. Nonostante questo procediamo comunque con i test di diagnostica, anche perchè analizzando attentamente ci sono alcune correlazioni significative: bisogna vedere se ciò è un problema.

Diagnostica

Test univariati

Passiamo quindi ad una fase di diagnostica: i primi test da effettuare sui residui sono quelli univariati, per autocorrelazione seriale e eteroschedasticità.

```r
pval=matrix(NA, 2, NCOL(mod1_resid))
colnames(pval)=colnames(mod1_resid)
rownames(pval)=c("r", "r^2")
for(i in 1:NCOL(mod1_resid)){
  # Test per autocorrelazione seriale
  pval[1,i]=Box.test(mod1_resid[,i], lag=10, type="Lj")$p.val
  # Test per effetti ARCH (eteroschedasticità)
  pval[2,i]=Box.test(mod1_resid[,i]^2, lag=10, type="Lj")$p.val
}
round(pval, 4)
```

```
     d_gdp  d_inv d_lungo d_breve
r   0.3476 0.0683  0.2962  0.9565
r^2 0.0000 0.7765  0.5280  0.7522
```

Nella tabella, dove le celle indicano i p-value per i relativi test/variabili , la prima riga testa l'ipotesi nulla di mancanza di autocorrelazione seriale. L'ipotesi non viene rifiutata e quindi possiamo concludere che non abbiamo autocorrelazione seriale residua.

La seconda riga testa l'ipotesi nulla di omoschedasticità: rifiutiamo quest'ipotesi soltanto per il PIL. Significa che i residui di questa variabile sono eteroschedastici, e ciò potrebbe rendere standard error e p-value inaffidabili. Proveremo con un VAR(2) per vedere se questo problema viene risolto.

Test multivariati

Passiamo ora ai test multivariati

```
# Test di Stabilità (Radici)
roots(mod1)
```

```
[1] 0.808341641 0.416381109 0.416381109 0.004858596
```

Il test sulle radici unitarie indica che tutte sono in modulo minori di 1, il che implica un processo stabile.

```
# Test di Normalità Multivariata (Jarque-Bera)
normality.test(mod1)
```

```
$JB

    JB-Test (multivariate)

data:  Residuals of VAR object mod1
Chi-squared = 203.96, df = 8, p-value < 2.2e-16


$Skewness

    Skewness only (multivariate)

data:  Residuals of VAR object mod1
Chi-squared = 14.761, df = 4, p-value = 0.005222


$Kurtosis

    Kurtosis only (multivariate)

data:  Residuals of VAR object mod1
Chi-squared = 189.2, df = 4, p-value < 2.2e-16
```

Il test Jarque-Brera, invece rifiuta l'ipotesi nulla di normalità dei residui; l'assenza di normalità è una cosa normale quando si lavora con variabili a livello macroeconomico.

Inoltre, vengono rifiutate entrambe le ipotesi nulle di solo asimmetria e curtosi: abbiamo entrambi i casi.

Passiamo ai test multivariati per l'autocorrelazione seriale

```
# Test per Autocorrelazione Seriale (Multivariato)
# Test Ljung-Box multivariato (Portmanteau)
serial.test(mod1, lags.pt=16, type = "PT.asymptotic")
```

```
    Portmanteau Test (asymptotic)

data:  Residuals of VAR object mod1
Chi-squared = 241.53, df = 240, p-value = 0.4601
```

```
#Test Breusch-Godfrey (LM Test)
serial.test(mod1, lags.bg = 16, type = "BG")
```

```
    Breusch-Godfrey LM test

data:  Residuals of VAR object mod1
Chi-squared = 263.8, df = 256, p-value = 0.3554
```

L'ipotesi nulla è la stessa del caso univariato, ovvero assenza di autocorrelazione seriale, e quindi il fatto che non rifiutiamo tutti e 2 i test implica che non c'è più autocorrelazione seriale.

Il test ARCH multivariato analizza l'ipotesi nulla di "omoschedasticità", ovvero che i residui abbiano una varianza costante nel tempo. Non rifituiamo l'ipotesi nulla dato il p-value elevato.

```
vars::arch.test(mod1, lags.multi = 10)
```

```
    ARCH (multivariate)

data:  Residuals of VAR object mod1
Chi-squared = 880, df = 1000, p-value = 0.9973
```

Causalità

I modelli VAR ci permettono di testare la causalità di Granger, ovvero possiamo andare se una serie y può essere predetta in maniera più efficiente utilizzando le informazioni di un altro processo x. Iniziamo con dei test di sistema

```
# Test di sistema (una variabile vs. tutte le altre)
# H0: La variabile 'cause' NON causa secondo Granger le altre
causality(mod1, cause="d_gdp")
```

```
$Granger

    Granger causality H0: d_gdp do not Granger-cause d_inv d_lungo d_breve

data:  VAR object mod1
F-Test = 20.031, df1 = 3, df2 = 372, p-value = 4.682e-12


$Instant

    H0: No instantaneous causality between: d_gdp and d_inv d_lungo d_breve

data:  VAR object mod1
Chi-squared = 22.804, df = 3, p-value = 4.436e-05
```

La prima ipotesi che facciamo è "PIL non causa le altre variabili secondo Granger". Rifiutiamo l'ipotesi e ciò che significa che PIL causa le altre variabili (viste in modo sistematico).

Inoltre abbiamo un secondo test, con ipotesi nulla di "Assenza di causalità istantenea tra PIL e le altre variabili". Rifiutiamo pure quest'ipotesi e quindi siamo in presenza di causalità istantanea.

```
causality(mod1, cause="d_inv")
```

```
$Granger

    Granger causality H0: d_inv do not Granger-cause d_gdp d_lungo d_breve

data:  VAR object mod1
F-Test = 2.283, df1 = 3, df2 = 372, p-value = 0.0787
```

```
$Instant

    H0: No instantaneous causality between: d_inv and d_gdp d_lungo d_breve

data:  VAR object mod1
Chi-squared = 13.552, df = 3, p-value = 0.003584
```

Invece per quanto riguardo gli investimenti, abbiamo che non rifiutiamo l'ipotesi nulla del test di sistema e che quindi gli investimenti non causano secondo Granger le altre variabili.

Viene rifiutata l'ipotesi di nessuna causalità istantanea.

```
causality(mod1, cause="d_lungo")
```

```
$Granger

    Granger causality H0: d_lungo do not Granger-cause d_gdp d_inv d_breve

data:  VAR object mod1
F-Test = 6.0146, df1 = 3, df2 = 372, p-value = 0.0005209


$Instant

    H0: No instantaneous causality between: d_lungo and d_gdp d_inv d_breve

data:  VAR object mod1
Chi-squared = 5.98, df = 3, p-value = 0.1126
```

Per quanto riguarda invece i tassi di interesse a lungo termine, rifiutiamo l'ipotesi nulla che gli investimenti non causino le altre variabili

Non rifiutiamo invece quella di nessuna causalità istantanea. Infine passiamo ai tassi a breve termine: in questo caso rifiutiamo entrambe le ipotesi nulle

```
causality(mod1, cause="d_breve")
```

```
$Granger

    Granger causality H0: d_breve do not Granger-cause d_gdp d_inv d_lungo

data:  VAR object mod1
```

```
F-Test = 4.9651, df1 = 3, df2 = 372, p-value = 0.002168


$Instant

    H0: No instantaneous causality between: d_breve and d_gdp d_inv d_lungo

data:  VAR object mod1
Chi-squared = 25.848, df = 3, p-value = 1.026e-05
```

Passiamo ora a dei test pairwise, dove riusciamo a mettere in confronto coppie di variabili.

Iniziamo analizzando la variabile PIL, e ci aspettiamo che sia causa di almeno una delle altre variabili, dato il risultato del test di sistema.

```
p=1

# Test 1: PIL Granger-causa x?
# H0: PIL NON Granger-causa x

grangertest(dati_ok[, "d_inv"] ~ dati_ok[, "d_gdp"],
            order = p)
```

```
Granger causality test

Model 1: dati_ok[, "d_inv"] ~ Lags(dati_ok[, "d_inv"], 1:1) + Lags(dati_ok[, "d_gdp"], 1:1)
Model 2: dati_ok[, "d_inv"] ~ Lags(dati_ok[, "d_inv"], 1:1)
  Res.Df Df      F    Pr(>F)
1     95
2     96 -1 51.471 1.584e-10 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
grangertest(dati_ok[, "d_lungo"] ~ dati_ok[, "d_gdp"],
            order = p)
```

```
Granger causality test

Model 1: dati_ok[, "d_lungo"] ~ Lags(dati_ok[, "d_lungo"], 1:1) + Lags(dati_ok[, "d_gdp"], 1
Model 2: dati_ok[, "d_lungo"] ~ Lags(dati_ok[, "d_lungo"], 1:1)
  Res.Df Df      F Pr(>F)
1     95
2     96 -1 0.2752 0.6011
```

```
grangertest(dati_ok[, "d_breve"] ~ dati_ok[, "d_gdp"],
            order = p)
```

```
Granger causality test

Model 1: dati_ok[, "d_breve"] ~ Lags(dati_ok[, "d_breve"], 1:1) + Lags(dati_ok[, "d_gdp"], 1
Model 2: dati_ok[, "d_breve"] ~ Lags(dati_ok[, "d_breve"], 1:1)
  Res.Df Df      F  Pr(>F)
1     95
2     96 -1 4.3331 0.04007 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Rifiutiamo l'ipotesi nulla nel caso degli investimenti e dei tassi brevi, significa che il PIL granger-causa gli investimenti e i tassi a breve termine.

Andiamo ad analizzare gli investimenti, aspettandoci di trovare che essi non granger-causino nessuna variabile.

```
grangertest(dati_ok[, "d_gdp"] ~ dati_ok[, "d_inv"],
            order = p)
```

```
Granger causality test

Model 1: dati_ok[, "d_gdp"] ~ Lags(dati_ok[, "d_gdp"], 1:1) + Lags(dati_ok[, "d_inv"], 1:1)
Model 2: dati_ok[, "d_gdp"] ~ Lags(dati_ok[, "d_gdp"], 1:1)
  Res.Df Df      F Pr(>F)
1     95
2     96 -1 1.9128 0.1699
```

```
grangertest(dati_ok[, "d_lungo"] ~ dati_ok[, "d_inv"],
            order = p)
```

```
Granger causality test

Model 1: dati_ok[, "d_lungo"] ~ Lags(dati_ok[, "d_lungo"], 1:1) + Lags(dati_ok[, "d_inv"], 1
Model 2: dati_ok[, "d_lungo"] ~ Lags(dati_ok[, "d_lungo"], 1:1)
  Res.Df Df      F Pr(>F)
1     95
2     96 -1 0.4225 0.5172
```

```
grangertest(dati_ok[, "d_breve"] ~ dati_ok[, "d_inv"],
            order = p)
```

```
Granger causality test

Model 1: dati_ok[, "d_breve"] ~ Lags(dati_ok[, "d_breve"], 1:1) + Lags(dati_ok[, "d_inv"], 1
Model 2: dati_ok[, "d_breve"] ~ Lags(dati_ok[, "d_breve"], 1:1)
  Res.Df Df      F Pr(>F)
1     95
2     96 -1 2.0677 0.1537
```

I risultati sono come aspettato, e non rifiutiamo nessuna delle ipotesi nulle: gli investimenti non granger-causano nè PIL nè tassi di interesse.

Passiamo ai tassi di interesse a lungo termine, dove ci aspettiamo di rifiutare almeno una di queste ipotesi: quella rifiutata è quella che quelli a lungo termine non causino quelli a breve termine.

```
grangertest(dati_ok[, "d_gdp"] ~ dati_ok[, "d_lungo"],
            order = p)
```

```
Granger causality test

Model 1: dati_ok[, "d_gdp"] ~ Lags(dati_ok[, "d_gdp"], 1:1) + Lags(dati_ok[, "d_lungo"], 1:1)
Model 2: dati_ok[, "d_gdp"] ~ Lags(dati_ok[, "d_gdp"], 1:1)
  Res.Df Df      F Pr(>F)
1     95
2     96 -1 0.9216 0.3395
```

```
grangertest(dati_ok[, "d_inv"] ~ dati_ok[, "d_lungo"],
            order = p)
```

```
Granger causality test

Model 1: dati_ok[, "d_inv"] ~ Lags(dati_ok[, "d_inv"], 1:1) + Lags(dati_ok[, "d_lungo"], 1:1)
Model 2: dati_ok[, "d_inv"] ~ Lags(dati_ok[, "d_inv"], 1:1)
  Res.Df Df      F Pr(>F)
1     95
2     96 -1 1.6495 0.2022
```

```
grangertest(dati_ok[, "d_breve"] ~ dati_ok[, "d_lungo"],
            order = p)
```

```
Granger causality test

Model 1: dati_ok[, "d_breve"] ~ Lags(dati_ok[, "d_breve"], 1:1) + Lags(dati_ok[, "d_lungo"],
Model 2: dati_ok[, "d_breve"] ~ Lags(dati_ok[, "d_breve"], 1:1)
  Res.Df Df      F  Pr(>F)
1     95
2     96 -1 5.4874 0.02124 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Vediamo cosa succede per i tassi a breve termine, dove rifiutiamo l'ipotesi che essi non causino il PIL.

```
grangertest(dati_ok[, "d_gdp"] ~ dati_ok[, "d_breve"],
            order = p)
```

```
Granger causality test

Model 1: dati_ok[, "d_gdp"] ~ Lags(dati_ok[, "d_gdp"], 1:1) + Lags(dati_ok[, "d_breve"], 1:1)
Model 2: dati_ok[, "d_gdp"] ~ Lags(dati_ok[, "d_gdp"], 1:1)
  Res.Df Df      F    Pr(>F)
1     95
2     96 -1 13.658 0.0003667 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
grangertest(dati_ok[, "d_inv"] ~ dati_ok[, "d_breve"],
            order = p)
```

```
Granger causality test

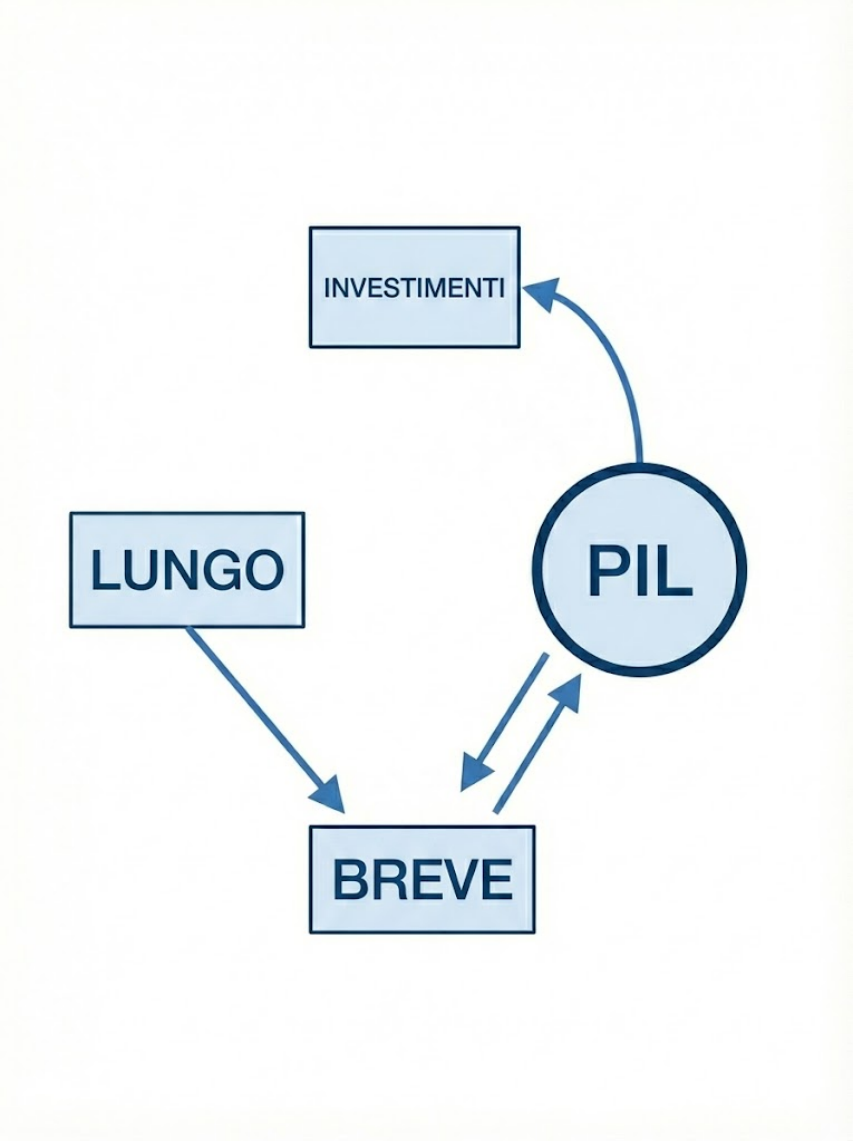
Model 1: dati_ok[, "d_inv"] ~ Lags(dati_ok[, "d_inv"], 1:1) + Lags(dati_ok[, "d_breve"], 1:1)
Model 2: dati_ok[, "d_inv"] ~ Lags(dati_ok[, "d_inv"], 1:1)
  Res.Df Df      F Pr(>F)
1     95
2     96 -1 0.0506 0.8225
```

```r
grangertest(dati_ok[, "d_lungo"] ~ dati_ok[, "d_breve"],
            order = p)
```

```
Granger causality test

Model 1: dati_ok[, "d_lungo"] ~ Lags(dati_ok[, "d_lungo"], 1:1) + Lags(dati_ok[, "d_breve"],
Model 2: dati_ok[, "d_lungo"] ~ Lags(dati_ok[, "d_lungo"], 1:1)
  Res.Df Df      F Pr(>F)
1     95
2     96 -1 0.4228 0.5171
```

Abbiamo trovato quindi la seguente forma di Granger-causalità nel sistema:



IRF

Ora, siamo interessati alla risposta delle variabili ad un impulso in un altra variabile all'interno del nostro sistema, e utilizziamo quindi la risposta d'impulso.

Dati quindi i risultati dei test di causalità di Granger, possiamo essere interessati a come investimenti (ed eventualmente i tassi) rispondono ad uno shock al PIL.

Imponiamo quindi un ordine dove uno:

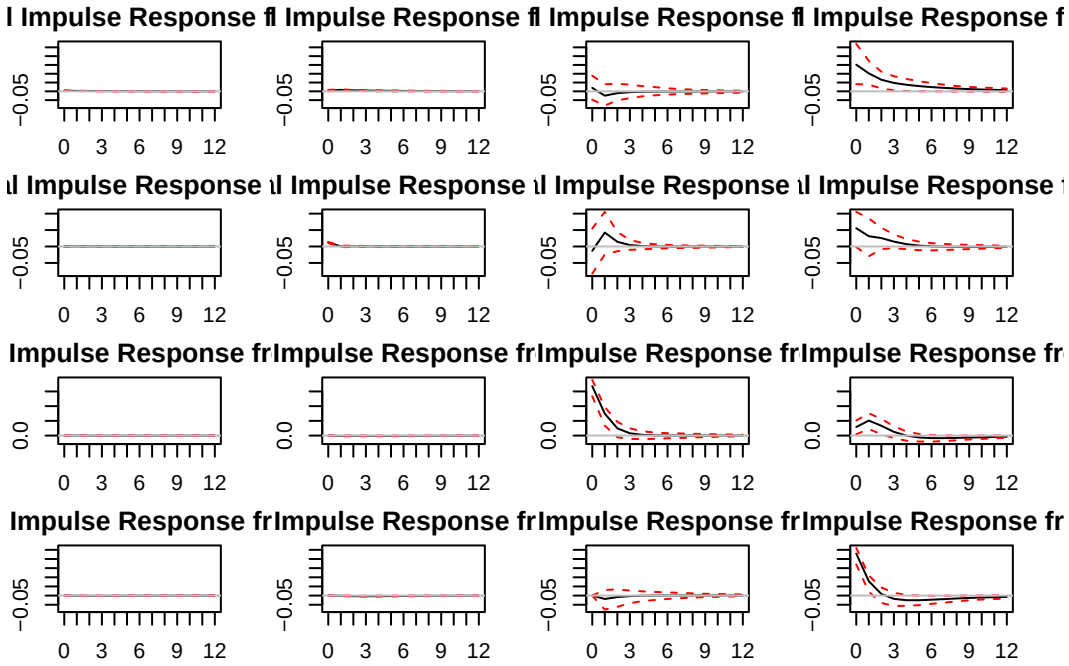
- shock al PIL può influenzare sia tassi che investimenti nello stesso periodo temporale

- shock ai tassi può influenzare gli investimenti nello stesso periodo
- shock agli investimenti influenza solo sè stesso nello stesso trimestre

$$PIL \rightarrow Lungo \rightarrow Breve \rightarrow Investimenti$$

```
irf1=irf(mod1,
         impulse = c("d_gdp", "d_lungo","d_breve","d_inv"),
         response = c("d_gdp", "d_lungo","d_breve", "d_inv"),
n.ahead = 12, boot = TRUE, ortho = TRUE, runs = 1000)


par(mfrow = c(4, 4), mar = c(2, 2, 2, 2))
plot(irf1, plot.type = "single")
```



Otteniamo i seguenti risultati:

- PIL
  - uno shock al PIL mostra un effetto trascurabile o nullo sui tassi a breve termine
  - si osserva un impatto positivo e istantaneo significativo sugli investimenti: questo effetto ha un picco al tempo 0 e cala nel tempo
- Tassi a lungo termine

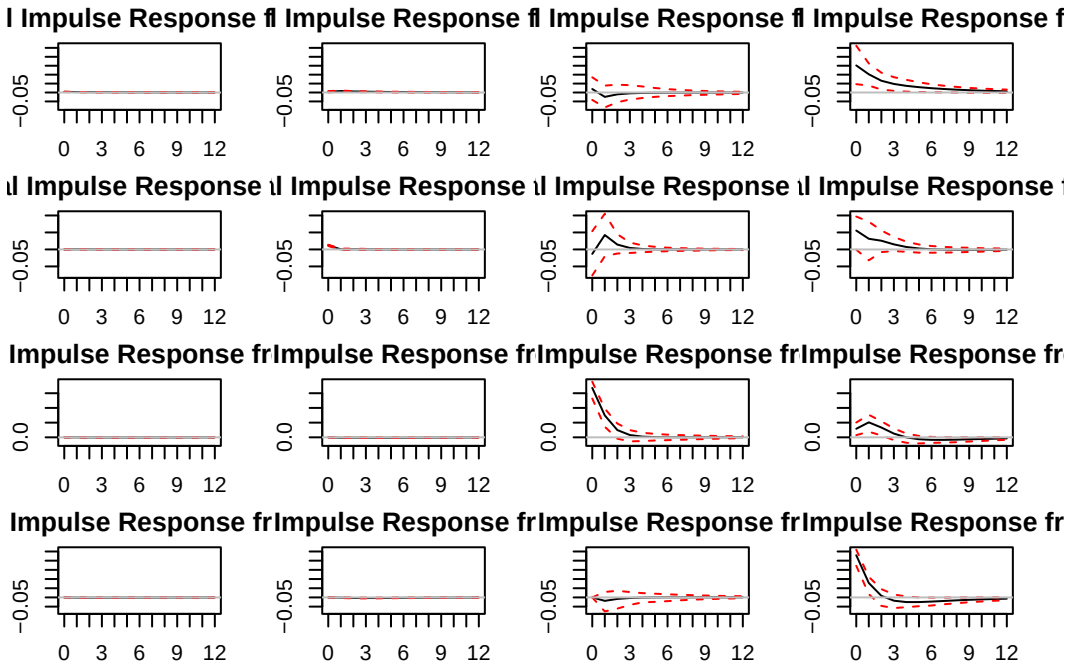
  - hanno effetto non istantaneo sui tassi a breve termine
  - si note invece un effetto istantaneo e che si azzera sugli investimenti

- C'è invece un forte effetto dello shock sui tassi a breve termine su sè stessi, ed uno non istantaneo sugli investimenti
- Infine uno shock sugli investimenti causa un effetto istantaneo e decrescente sugli investimenti stessi

Potremmo comunque cambiare l'ordine delle variabili e analizzare differenti shock, ad esempio inizialmente ci si aspettava che fossero i tassi di interesse ad influenzare le altre variabili, proviamo con un ordine dove uno shock sui tassi possa avere effetto sulle altre 2 variabili.

```
irf2=irf(mod1,
         impulse = c("d_lungo","d_breve", "d_gdp","d_inv"),
         response = c("d_lungo","d_breve","d_gdp", "d_inv"),
n.ahead = 12, boot = TRUE, ortho = TRUE, runs = 1000)


par(mfrow = c(4, 4), mar = c(2, 2, 2, 2))
plot(irf2, plot.type = "single")
```



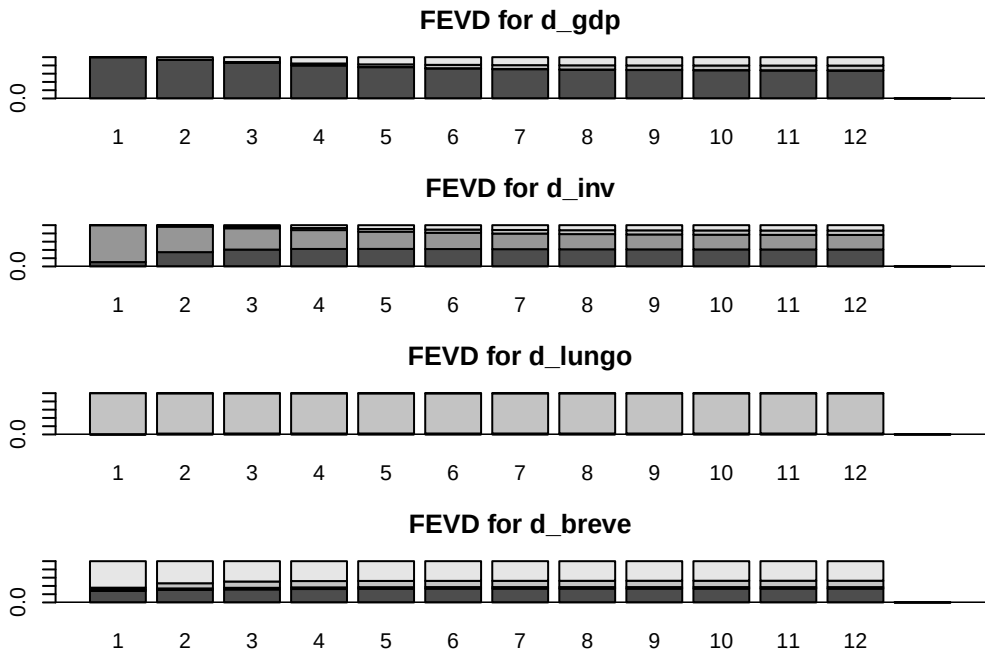
- Investimenti a lungo termine hanno effetto su quelli a breve termine e sugli investimenti

- Investimenti a breve termine invece su PIL e investimenti
- PIL su sè stesso e sugli investimenti
- Investimenti, come prima, hanno effetto su sè stessi

FEVD

Un'ulteriore analisi che i modelli VAR ci permettono di effettuare è la decomposizione della varianza, la quale ci permette di captare la proporzione di movimenti nella variabile dipendente che sono dovuti a shock propri rispetto a shock di altre variabile.

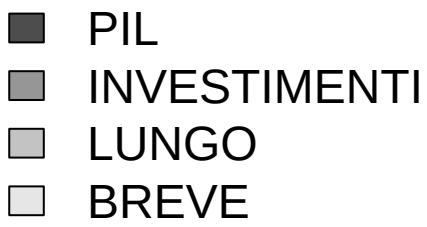
```
fevd1=fevd(mod1, n.ahead = 12)
par(mar = c(2, 2, 3, 3))
plot(fevd1, legend=F)
```




```
plot.new()
nomi_legenda <- c("PIL", "INVESTIMENTI", "LUNGO", "BREVE")
colori_legenda <- grey.colors(4, start = 0.3, end = 0.9) # Dal più scuro al più chiaro

# 3. Disegna la legenda al centro della finestra
legend("center",
       legend = nomi_legenda,
       fill = colori_legenda,
```

```
       title = "SORGENTE DELLO SHOCK",
       title.font = 2,      # Titolo in grassetto
       cex = 1.5,           # Ingrandisce il testo per renderlo chiaro
       bty = "n",           # Rimuove il bordo della scatola
       ncol = 1,            # Mette i nomi in colonna (o usa 2 per farla orizzontale)
       border = "black")    # Bordo nero intorno ai quadratini colorati
```



Otteniamo che:

- la maggior parte della varianza dell'errore di previsione del PIL è dovuta a sè stesso, e significa che non viene influenzato da investimenti e tassi. Anche se con il tempo questa cosa diminuisce
- i tassi lunghi solo da sè stessi, hanno un ruolo esogeno nel sistema
- Diverso per quanto riguarda gli investimenti, uno shock sul PIL sembra colpirli, soprattutto dopo alcuni trimestri. Dopo il 5 trimestre in realtà più della metà della varianza è data proprio dal PIL. Significa che la variabile investimenti nel nostro sistema è una variabile endogena.
- pure i tassi a breve termine pure dal PIL, cosa che aumenta per poi assestarsi

VAR(2)

Il modello VAR(1) sembra dare risultati soddisfacenti, soprattutto riguardo la diagnostica.

L'unico "problema" riscontrato è dovuto alla presenza di eteroschedasticità nei residui del PIL, e quindi possiamo andare a vedere se ciò si "cura" stimando un VAR(2).

```
mod2=vars::VAR(dati_ok, p = 2, type = "const")

mod2_resid=resid(mod2)

pval=matrix(NA, 2, NCOL(mod1_resid))
colnames(pval)=colnames(mod1_resid)
```

```r
rownames(pval)=c("r", "r^2")
for(i in 1:NCOL(mod1_resid)){
  # Test per autocorrelazione seriale
  pval[1,i]=Box.test(mod1_resid[,i], lag=10, type="Lj")$p.val
  # Test per effetti ARCH (eteroschedasticità)
  pval[2,i]=Box.test(mod1_resid[,i]^2, lag=10, type="Lj")$p.val
}
round(pval, 4)
```

```
     d_gdp  d_inv d_lungo d_breve
r   0.3476 0.0683  0.2962  0.9565
r^2 0.0000 0.7765  0.5280  0.7522
```

```r
#
```

Non cambia nulla, rimane eteroschedasticità, e per semplicità di interpretazione, oltre per non andare a stimare modelli sovraparametrizzati, decidiamo comunque di fidarci del VAR(1).

Nonostante ciò, nel paragrafo designato alle previsioni, andremo a controllare se le previsioni del VAR(2) migliorano significativamente rispetto al caso p=1.

VECM

Precedentemente nel documento, è stato confermato che le serie iniziali non sono stazionarie, e che esse fossero tutte I(1), tranne i tassi a breve termine, definiti come stazionari attorno ad un trend. Tuttavia, è possibile che esse siano cointegrate tra di loro, ovvero che esista una relazione a lungo termine.

Cosa afferma la teoria economica nel nostro caso?

Secondo i modelli di crescita neoclassica, nel lungo periodo l'economia tende a un Balanced Growth Path. In equilibrio il rapporto tra investimenti e PIL è costante nel tempo.

Gli investimenti dipendono dal costo del finanziamento. Se i tassi a lungo termine scendono, il costo opportunità del capitale diminuisce, rendendo redditizi più progetti di investimento.

Il PIL reale e i tassi di interesse reali sono legati dalla produttività marginale del capitale. Un'economia che cresce velocemente (PIL alto) solitamente richiede tassi di interesse più elevati per bilanciare risparmi e investimenti.

Approccio di Johansen

Per trovare i vettori di cointegrazione, il primo step necessario è quello di stimare un modello VAR sulle variabili originarie. Quindi usiamo i tassi a breve e lungo termine, e il logaritmo di PIL e investimenti.

```
train_log=train
train_log[,1]=log(train[,1])
train_log[,2]=log(train[,2])


lag_select=VARselect(train_log, lag.max = 8, type = "both")
lag_select$selection
```

```
AIC(n)  HQ(n)  SC(n) FPE(n)
     2       2       2       2
```

```
#tutti dicono 2, ottimo
```

I criteri di informazione sono d'accordo che il numero ottimale di lag sia 2. Per trovare ora il numero di vettori di cointegrazione utilizziamo la funzione ca.jo, e la usiamo per fare 2 tipi diversi di test, ma con la stessa funzione: il test della traccia e il test dell'autovalore massimo.

Procediamo con il test della traccia. Dati i risultati del test ADF di presenza di trend per i tassi a breve termineutilizziamo type="trend"

```
vecm_jo=ca.jo(train_log, type = "trace",
              ecdet = "trend", K = 2, spec = "longrun")
summary(vecm_jo)
```

```
######################
# Johansen-Procedure #
######################

Test type: trace statistic , with linear trend in cointegration

Eigenvalues (lambda):
[1]  3.130802e-01  2.735535e-01  2.091547e-01  4.497183e-02 -1.387779e-17

Values of teststatistic and critical values of test:
```

```
          test 10pct  5pct  1pct
r <= 3 |  4.51 10.49 12.25 16.26
r <= 2 | 27.51 22.76 25.32 30.45
r <= 1 | 58.83 39.06 42.44 48.45
r = 0  | 95.63 59.14 62.99 70.05

Eigenvectors, normalised to first column:
(These are the cointegration relations)

               PIL.l2       Inv.l2     Lungo.l2     Breve.l2     trend.l2
PIL.l2    1.000000000  1.000000000  1.000000000  1.000000000  1.000000000
Inv.l2   -0.357008356 -0.269117334 -0.249938856 -0.549639583 -0.332634027
Lungo.l2 -0.008654061  0.010859380  0.074951084 -0.015831886  0.002977242
Breve.l2  0.014780410 -0.012163289  0.040889263  0.013455344 -0.012945709
trend.l2 -0.003095013 -0.003282619  0.003977628 -0.003096176 -0.005098813

Weights W:
(This is the loading matrix)

             PIL.l2      Inv.l2    Lungo.l2    Breve.l2      trend.l2
PIL.d   -0.08510073 -0.02620843 -0.01147013 -0.01480471  1.671125e-12
Inv.d   -0.30637462  0.14549818 -0.02984554  0.06052483  1.486737e-12
Lungo.d  7.31464583  3.25202682 -1.23779567 -0.58291366 -1.022668e-10
Breve.d -4.95989832  5.03819255 -0.36108552 -1.48776144  4.541068e-11
```

```r
#r0 superiore a stat test, rifiuto h0 che r=0
#r<=1 rifiuto che r=1
#<=2 pure rifiuto
#<= minore, non rifiuto
```

Per quanto riguarda il test della traccia, rifiutiamo quando la statistica test è maggiore del valore critico, abbiamo 3 vettori di cointegrazione

Andiamo a vedere con il test dell'autovalore massimo se i risultati coincidono.

```r
#test dell'Autovalore Massimo (Max Eigenvalue)
vecm_eigen=ca.jo(train_log, type = "eigen", ecdet = "trend",
                 K = 2, spec = "longrun")
summary(vecm_eigen)
```

```
######################
```

```
# Johansen-Procedure #
######################

Test type: maximal eigenvalue statistic (lambda max) , with linear trend in cointegration

Eigenvalues (lambda):
[1]  3.130802e-01  2.735535e-01  2.091547e-01  4.497183e-02 -1.387779e-17

Values of teststatistic and critical values of test:

          test 10pct  5pct  1pct
r <= 3 |  4.51 10.49 12.25 16.26
r <= 2 | 23.00 16.85 18.96 23.65
r <= 1 | 31.32 23.11 25.54 30.34
r = 0  | 36.80 29.12 31.46 36.65

Eigenvectors, normalised to first column:
(These are the cointegration relations)

               PIL.l2       Inv.l2     Lungo.l2     Breve.l2     trend.l2
PIL.l2    1.000000000  1.000000000  1.000000000  1.000000000  1.000000000
Inv.l2   -0.357008356 -0.269117334 -0.249938856 -0.549639583 -0.332634027
Lungo.l2 -0.008654061  0.010859380  0.074951084 -0.015831886  0.002977242
Breve.l2  0.014780410 -0.012163289  0.040889263  0.013455344 -0.012945709
trend.l2 -0.003095013 -0.003282619  0.003977628 -0.003096176 -0.005098813

Weights W:
(This is the loading matrix)

             PIL.l2      Inv.l2    Lungo.l2    Breve.l2      trend.l2
PIL.d   -0.08510073 -0.02620843 -0.01147013 -0.01480471  1.671125e-12
Inv.d   -0.30637462  0.14549818 -0.02984554  0.06052483  1.486737e-12
Lungo.d  7.31464583  3.25202682 -1.23779567 -0.58291366 -1.022668e-10
Breve.d -4.95989832  5.03819255 -0.36108552 -1.48776144  4.541068e-11
```

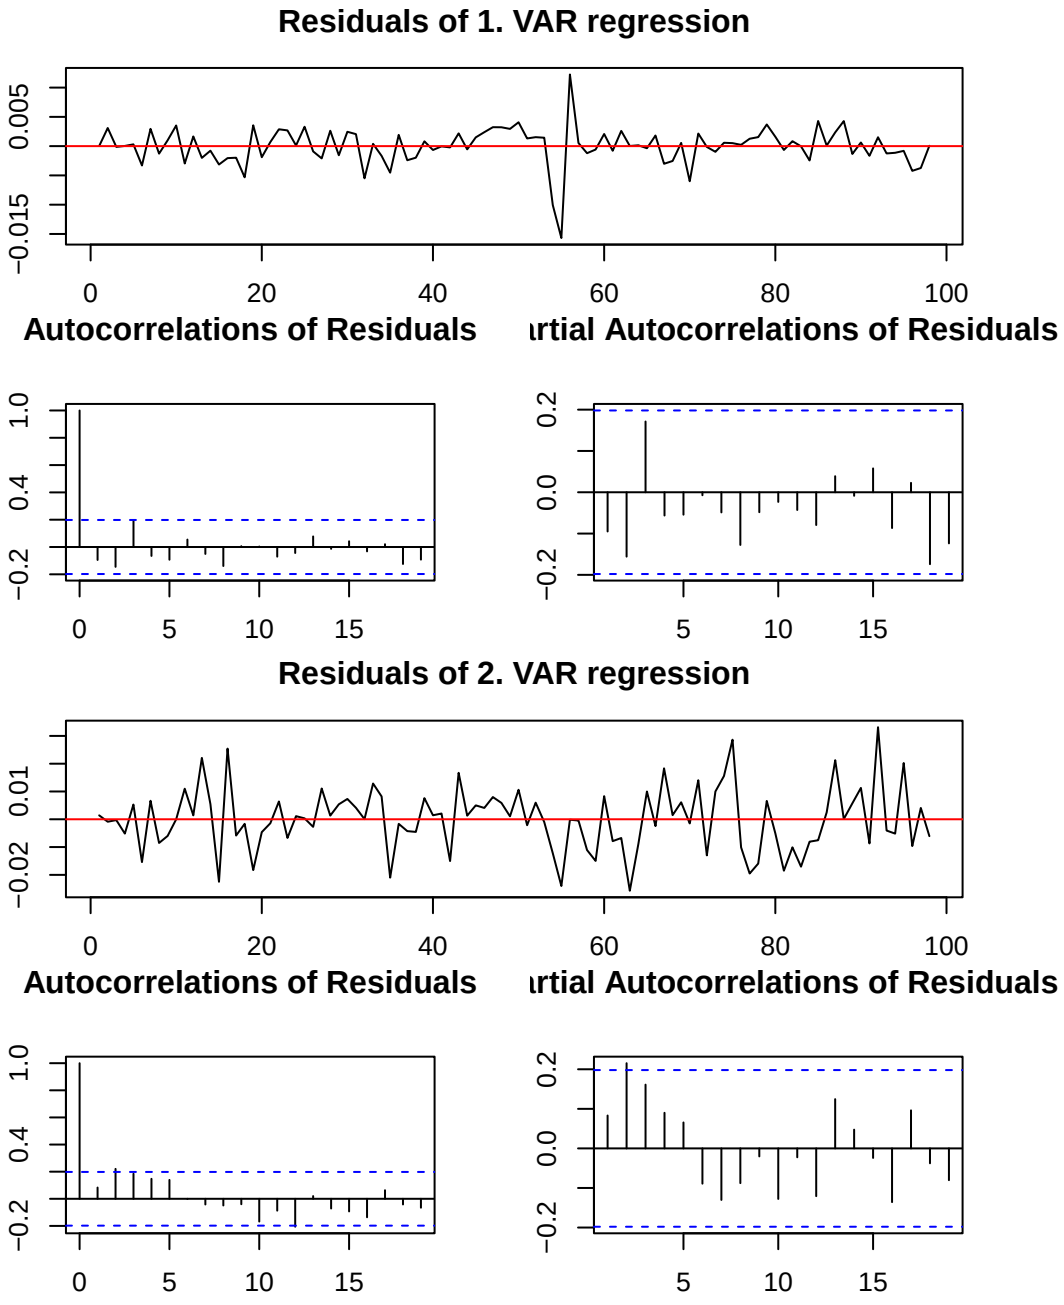
```
#rango di cointegrazione=3, 3 vettori di cointegrazione
```

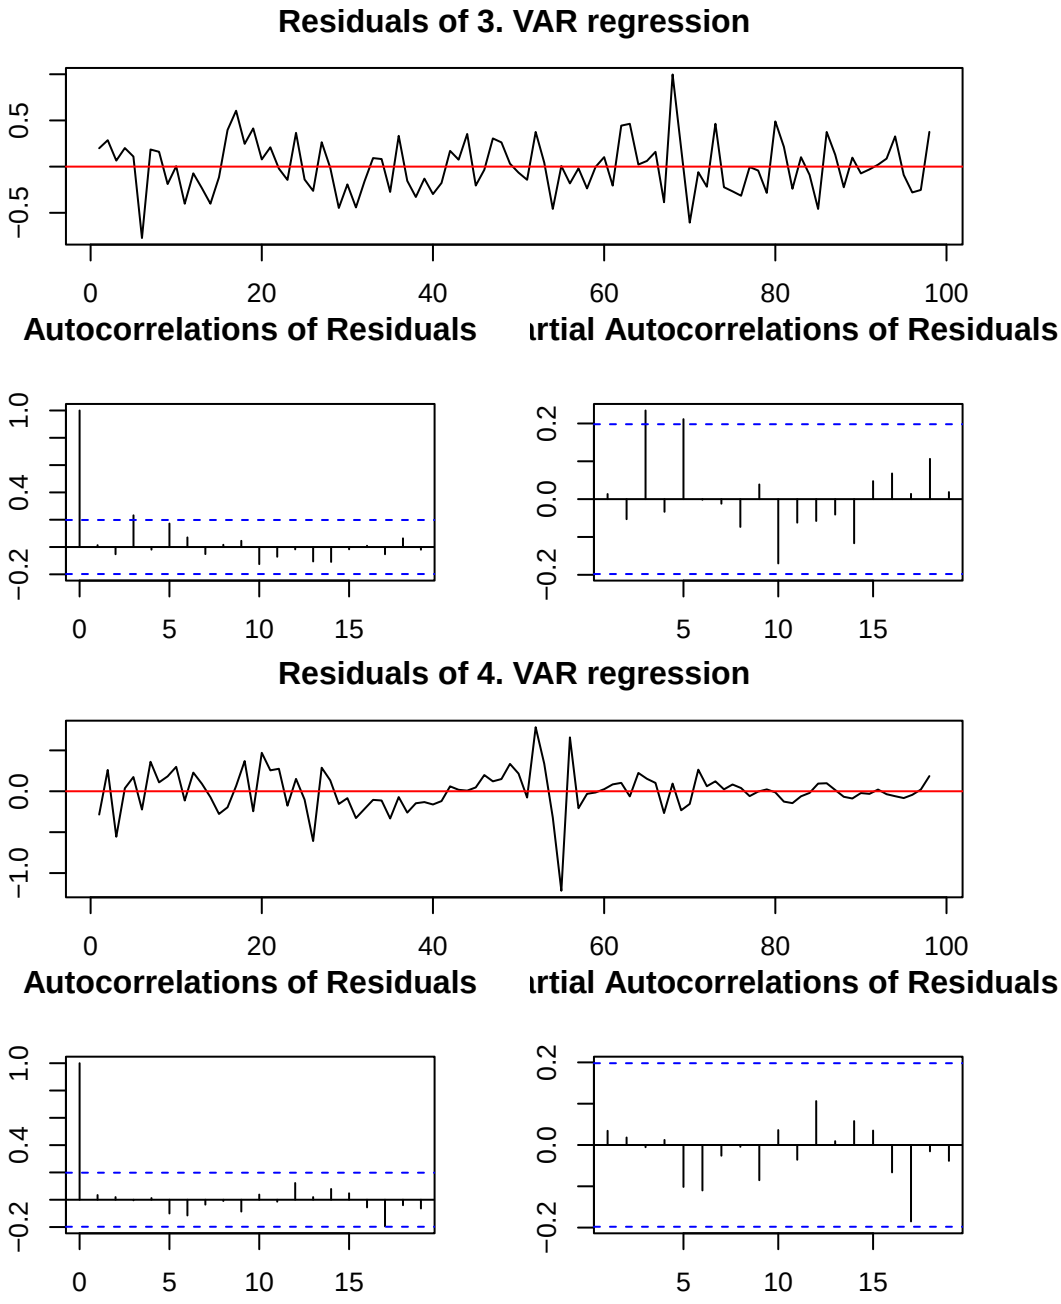
Rifiutiamo l'ipotesi nulla che r=0 dato che la statistica test è uguale a 36.80 ed è maggiore del valore critico con livello 0.05.

L'unica ipotesi che non rifiutiamo è che r<=3: la statistica test è uguale a 4.51 ed è minore del valore critico di 12.25.

Significa che i test della traccia e dell'autovalore sono d'accordo e entrambi mostrano che il numero di vettori di cointegrazione è 3

```
par(mar = c(2, 2, 3, 3))
plotres(vecm_jo)
```





Vettore di cointegrazione

```
vecm_rls=cajorls(vecm_jo, r = 3)
```

```
#coef di relazione nel lungo periodo
print(vecm_rls$beta)
```

```
                 ect1          ect2          ect3
PIL.l2    1.000000e+00  8.881784e-16  0.000000e+00
Inv.l2    0.000000e+00  1.000000e+00 -8.881784e-16
Lungo.l2  1.387779e-17  0.000000e+00  1.000000e+00
Breve.l2 -1.642075e-01 -5.252302e-01  9.849273e-01
trend.l2 -1.247302e-02 -2.922625e-02  1.220246e-01
```

```
#aggiustamento
print(vecm_rls$rlm$coefficients[grep("ect",
                                     rownames(vecm_rls$rlm$coefficients)), ])
```

```
             PIL.d        Inv.d    Lungo.d     Breve.d
ect1 -0.1227792888 -0.190721983  9.3288770 -0.28279129
ect2  0.0403016454  0.077681779 -3.1771932  0.50510950
ect3 -0.0004078391  0.001994449 -0.1207605  0.07057116
```

Abbiamo ottenuto:

- 3 relazioni di lungo periodo:

$$ln(PIL) = 0.164 * breve + 0.012 * trend$$

$$ln(investimenti) = 0.525 * breve + 0.029 * trend$$

$$lungo = -0.985 * breve - 0.122 * trend$$

- C'è quindi una relazione di lungo periodo tra PIL e tassi breve e tra investimenti e tassi breve e tra lunghi e brevi. Sono quindi i tassi a breve termine a reagire agli shock, mentre le altre trainano il ritmo
- Coefficienti di aggiustamento:
  - nella prima relazione sono i tassi a lungo termine ad avere un ruolo endogeno, ovvero di reazione ai cambiamenti: segno positivo indica che essi aumentano per tornare all'equilibrio
  - Hanno lo stesso ruolo nelle altre relazioni, ma con effetto negativo

TFM

I modelli stimati fino ad'ora hanno dato risultati interessanti e delle belle interpretazione e a livello economico. Tuttavia, come anticipato ad inizio documento, siamo interessati a capire se una variabile può essere scritta in funzione di una seconda, e possiamo verificare ciò usando i modelli a funzione di trasferimento.

Dato che in questi modelli abbiamo bisogno di una variabile di input e di una di output, dobbiamo scegliere 2 delle 3 variabili totali, e per la scelta possiamo utilizzare i risultati visti fino ad'ora.

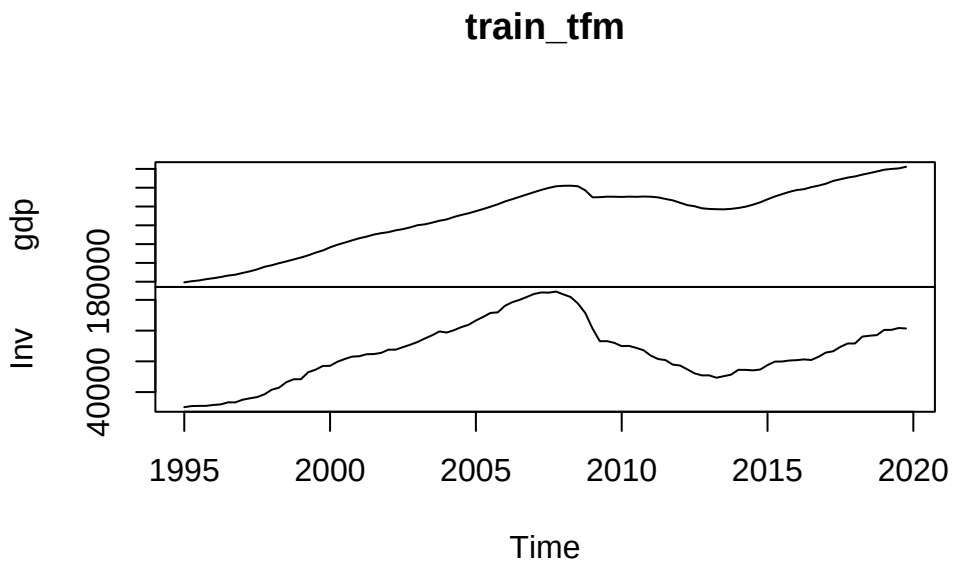
Ad esempio abbiamo visto nei VAR, e in particolare nell'analisi della causalità di Granger, che il PIL granger-causa gli investimenti. Usiamo quindi PIL come variabile di input e gli investimenti come output

```
dati=read_excel("data/economici_dati.xlsx")
dati=ts(dati[, 2:4],start = c(1995, 1),frequency = 4)
colnames(dati)=c("gdp","Inv","Lungo")

dati_tfm=dati[,c(1,2)]
#plot.ts(dati_tfm)

train_tfm=window(dati_tfm, end = c(2019, 4))
test_tfm=window(dati_tfm, start = c(2020, 1))

plot(train_tfm)
```

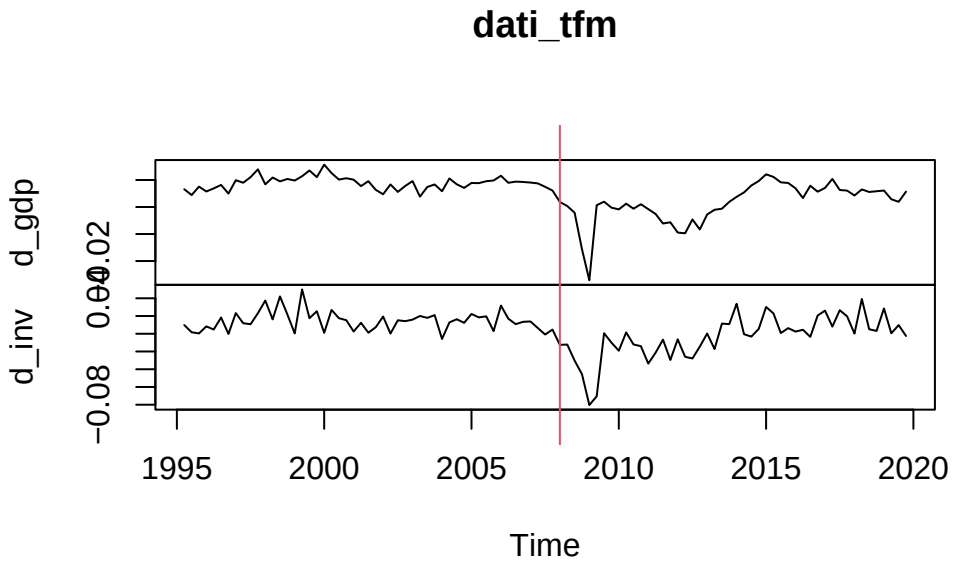


Le variabili di interesse rimangono non stazionarie: dobbiamo anche in questo caso usare la differenza logaritmica

```
d_gdp=diff(log(train[,1]))
d_inv=diff(log(train[,2]))

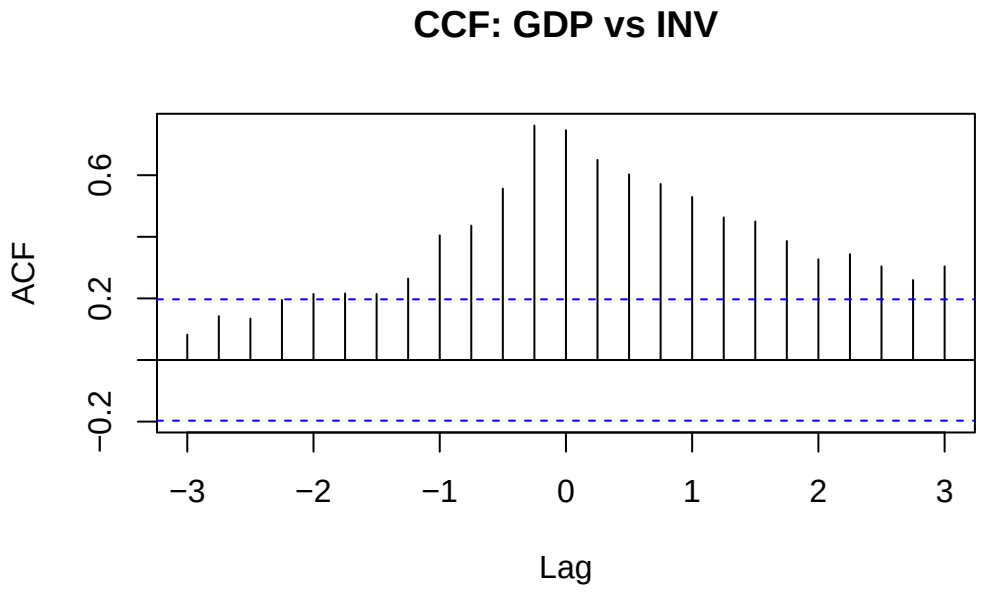
dati_tfm=cbind(d_gdp, d_inv)

plot.ts(dati_tfm)
abline(v=2008,col=2)
```



In realtà dalla funzione di cross-correlazione non si capiscono ottimamente le relazioni tra variabili. Tuttavia per capire bene le relazioni tra le 2 variabili sono necessari degli step preliminari.

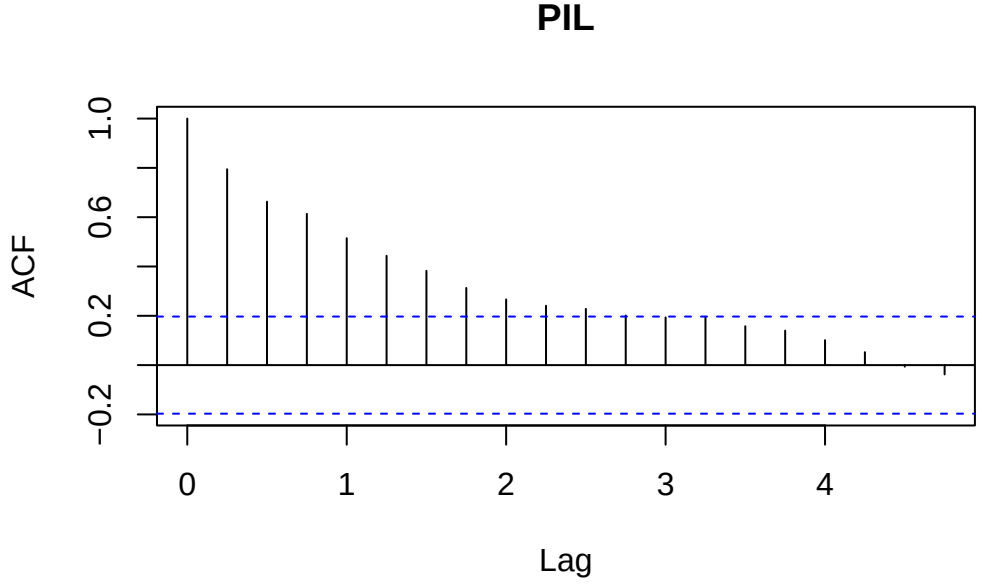
```
ccf(dati_tfm[,1], dati_tfm[,2], main = "CCF: GDP vs INV",
    lag.max = 12)
```



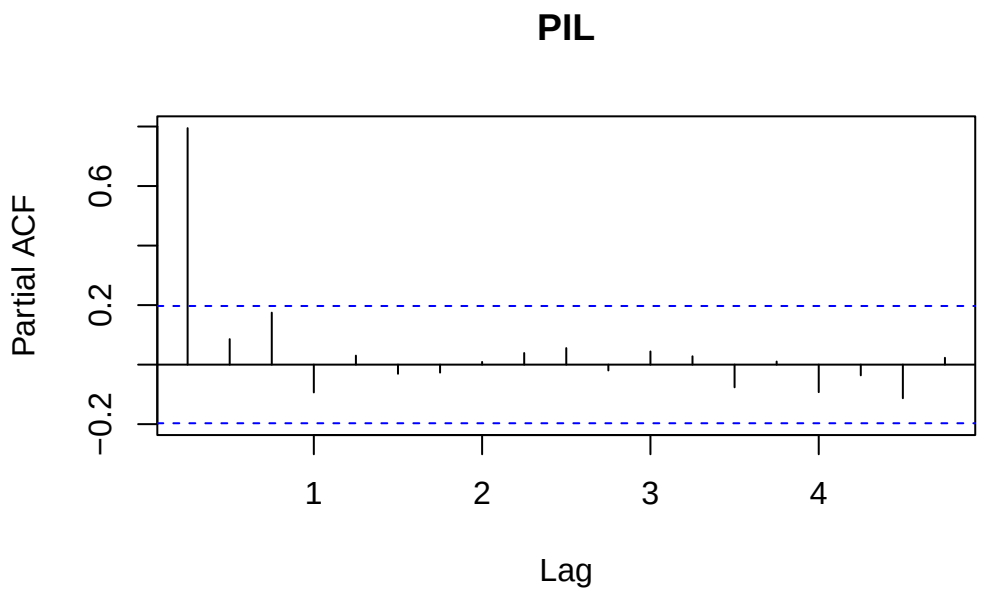
Serie Input

Innanzitutto è necessario sbiancare la serie di input, andando a stimare un corretto modello ARIMA per essa.

```
acf(dati_tfm[, 1], main = colnames(train)[1])
```



```r
pacf(dati_tfm[, 1], main = colnames(train)[1])
```



Nel nostro caso sembra di essere nel caso di un modello autoregressivo, iniziamo con ordine p=1 e poi vediamo.

```r
x=dati_tfm[,1]
library(forecast)
mod1=Arima(x, order=c(1,0,0), include.mean = T,
           include.drift = F)
summary(mod1)
```

```
Series: x
ARIMA(1,0,0) with non-zero mean

Coefficients:
         ar1    mean
      0.7872  0.0053
s.e.  0.0597  0.0018

sigma^2 = 1.563e-05:  log likelihood = 407.83
AIC=-809.65   AICc=-809.4   BIC=-801.87

Training set error measures:
                       ME        RMSE         MAE      MPE     MAPE      MASE
Training set -1.462277e-05 0.003913674 0.00251839 55.78836 95.42608 0.5937984
```

```
                     ACF1
Training set -0.05871618
```

```
mod2=Arima(x, order=c(2,0,0), include.mean = T,
           include.drift = F)
summary(mod2)
```

```
Series: x
ARIMA(2,0,0) with non-zero mean

Coefficients:
         ar1     ar2    mean
      0.7206  0.0830  0.0053
s.e.  0.0997  0.0998  0.0019

sigma^2 = 1.568e-05:  log likelihood = 408.17
AIC=-808.34   AICc=-807.92   BIC=-797.96

Training set error measures:
                       ME        RMSE         MAE      MPE     MAPE      MASE
Training set -1.49803e-05 0.003899862 0.002516474 52.89288 95.74304 0.5933468
                     ACF1
Training set -0.007977611
```

```
#no

mod3=Arima(x, order=c(1,0,1), include.mean = T,
           include.drift = F)
summary(mod3)
```

```
Series: x
ARIMA(1,0,1) with non-zero mean

Coefficients:
         ar1      ma1    mean
      0.8452  -0.1624  0.0053
s.e.  0.0687   0.1451  0.0020

sigma^2 = 1.562e-05:  log likelihood = 408.39
AIC=-808.77   AICc=-808.35   BIC=-798.39
```

```
Training set error measures:
                       ME        RMSE         MAE      MPE     MAPE      MASE
Training set -1.521147e-05 0.003891266 0.002508641 48.06138 93.04403 0.5914999
                   ACF1
Training set 0.0237449
```

```r
#no

mod4=Arima(x, order=c(1,0,0), include.mean = F, include.drift =F)
summary(mod4)
```

```
Series: x
ARIMA(1,0,0) with zero mean

Coefficients:
         ar1
      0.8726
s.e.  0.0470

sigma^2 = 1.626e-05:  log likelihood = 405.13
AIC=-806.25   AICc=-806.13   BIC=-801.06

Training set error measures:
                       ME       RMSE         MAE      MPE     MAPE      MASE
Training set 0.0006881355 0.00401238 0.002595153 58.20287 92.73924 0.6118981
                    ACF1
Training set -0.1377083
```

```r
#top
mod1$bic #questo
```

```
[1] -801.867
```

```r
mod4$bic
```

```
[1] -801.0644
```

```r
vediamo=forecast::auto.arima(x, seasonal = FALSE,
                             d = 0, D = 0)
summary(vediamo)
```

```
Series: x
ARIMA(1,0,0) with non-zero mean

Coefficients:
         ar1    mean
      0.7872  0.0053
s.e.  0.0597  0.0018

sigma^2 = 1.563e-05:  log likelihood = 407.83
AIC=-809.65   AICc=-809.4   BIC=-801.87

Training set error measures:
                       ME        RMSE         MAE      MPE     MAPE      MASE
Training set -1.462277e-05 0.003913674 0.00251839 55.78836 95.42608 0.5937984
                    ACF1
Training set -0.05871618
```

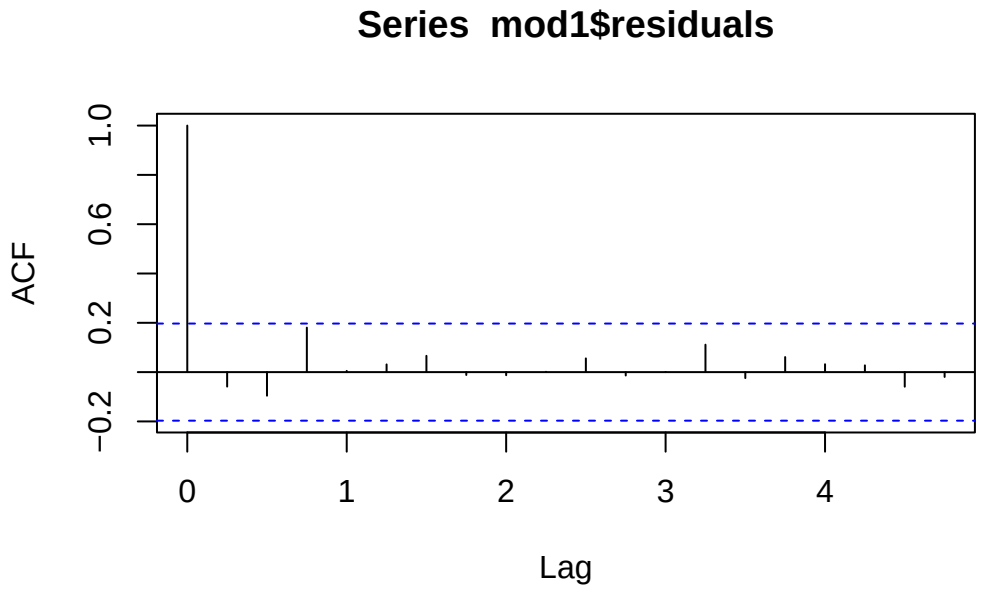
```
#è d'accordo co n noi

vediamo$bic
```

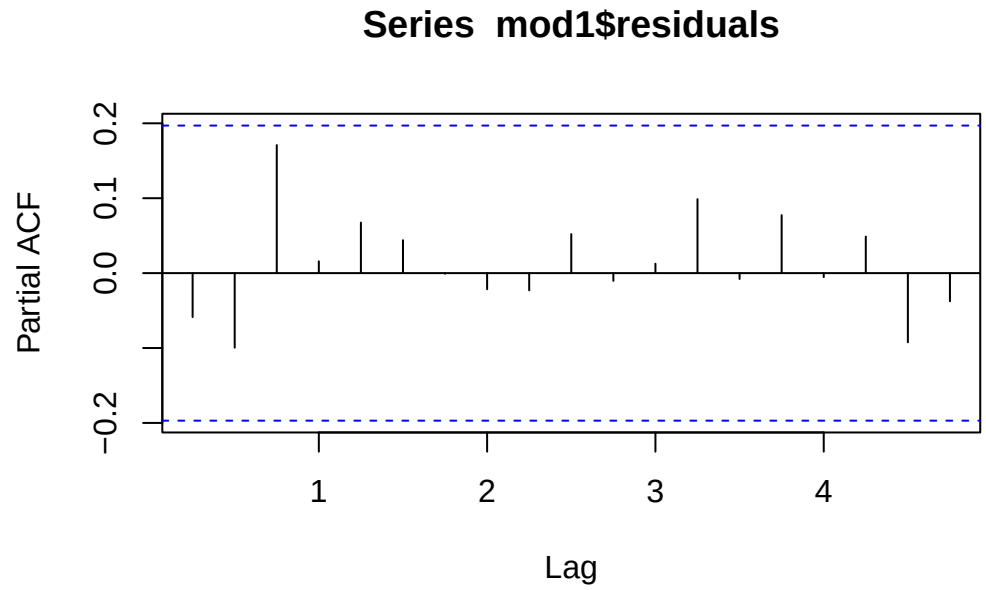
```
[1] -801.867
```

Viene quindi selezionato un AR(1) sulla serie differenziata, quindi ARIMA (1,1,0) sulla serie originale, vediamo se c'è autocorrelazione dei residui.

```
acf(mod1$residuals)
```




```
pacf(mod1$residuals)
```




```
alpha=mod4$residuals
```

Possiamo essere tranquilli in quanto i residui non sono autocorrelati. Inoltre la funzione auto.arima seleziona il medesimo modello.s

Serie output

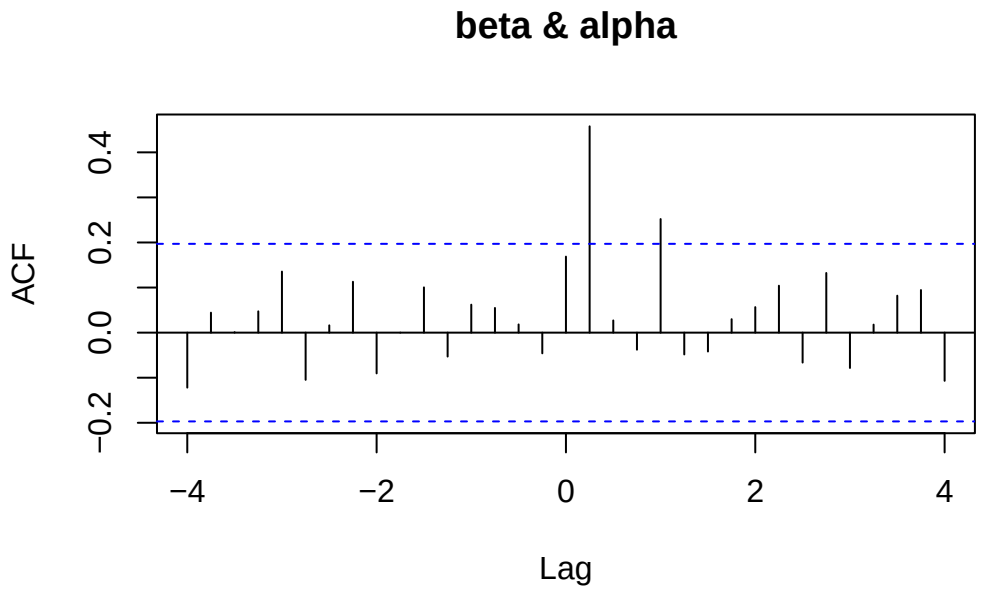
Dopo aver applicato il modello ARIMA alla serie di input, è necessario applicare la stessa trasformazione alla serie di output, quindi agli investimenti.

```
y=dati_tfm[,2]
mody=Arima(y, order=c(1,0,0), include.mean = T,
           include.drift =F)
beta=mody$residuals
```

CCF

Possiamo quindi controllare la funzione di cross-correlazione tra i residui di x e y, in modo da andare a scegliere gli ordini b,s e r per la funzione di trasferimento.

```
ccf(beta,alpha)
```




```
#b=1, primo lag significativo al lag 1
#s=0 non c'è pattern autoregressivo
#r=0, non va su e poi scende
```

```
library(MTS)
```

```
Warning: il pacchetto 'MTS' è stato creato con R versione 4.6.1
```

```
Caricamento pacchetto: 'MTS'

Il seguente oggetto è mascherato da 'package:vars':

    VAR
```

```
#con r=0 non riesce a stimare
#tfm1=MTS::tfm1(y,x,orderN=c(1,0,0), orderX=c(0,0,1))
#r,s,b

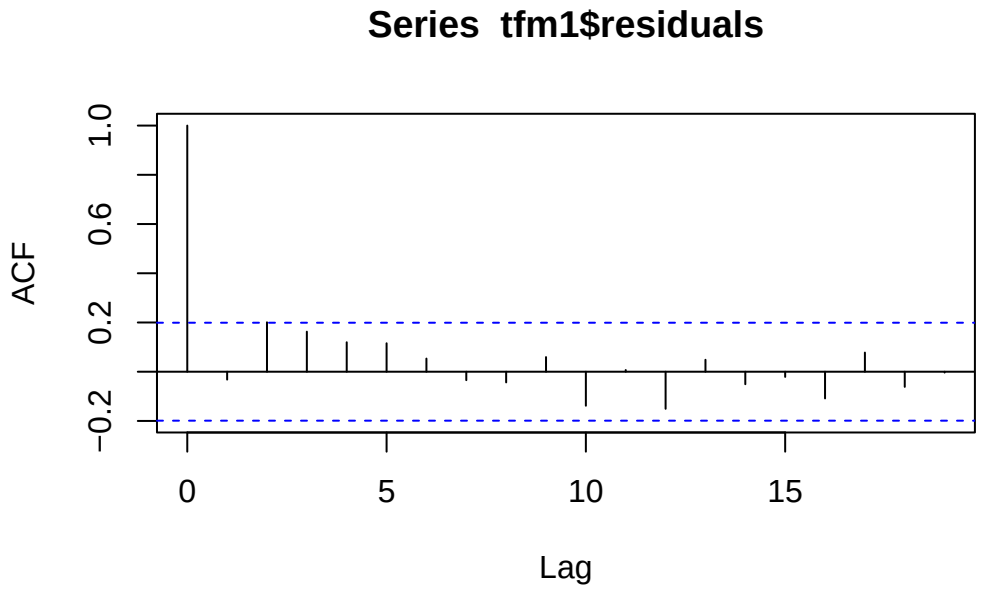
#proviamo con r=1
tfm1=MTS::tfm1(y,x,orderN=c(1,0,0), orderX=c(1,0,1))
```

```
Warning in nlm(Nlike, par, hessian = TRUE, dY = dY, dX = dX, orderN = orderN, :
Inf replaced by maximum positive value

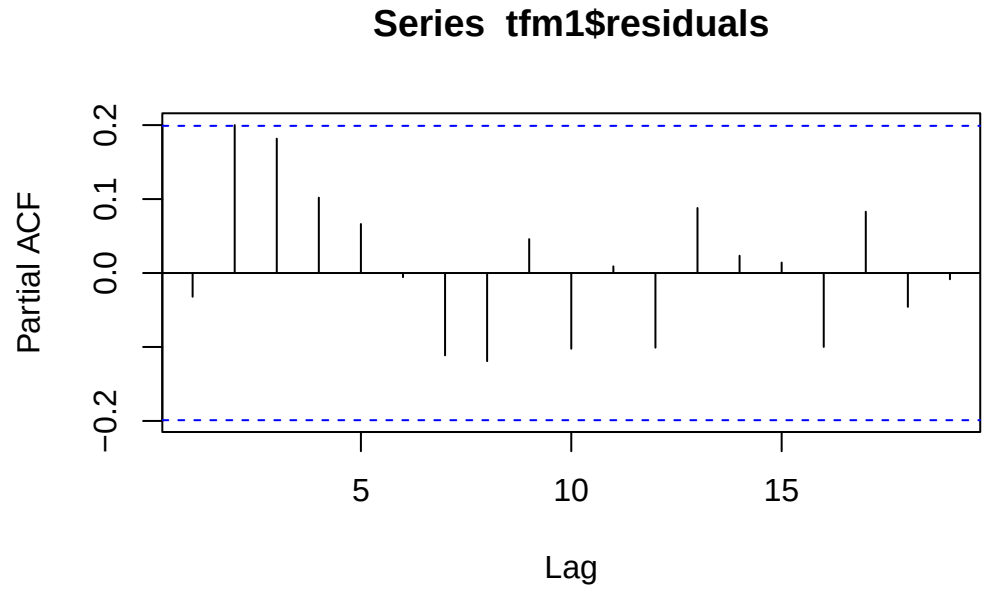
Warning in nlm(Nlike, par, hessian = TRUE, dY = dY, dX = dX, orderN = orderN, :
Inf replaced by maximum positive value

Delay:  1
Transfer function coefficients & s.e.:
in the order: constant, omega, and delta: 1 1 1
         [,1]  [,2]    [,3]
v    -0.00660 2.522 -0.0908
se.v  0.00202 0.337  0.1281
ARMA order:
[1] 1 0 0
ARMA coefficients & s.e.:
           [,1]
coef.arma 0.138
se.arma   0.108
```

```
acf(tfm1$residuals)
```




```
pacf(tfm1$residuals)
```



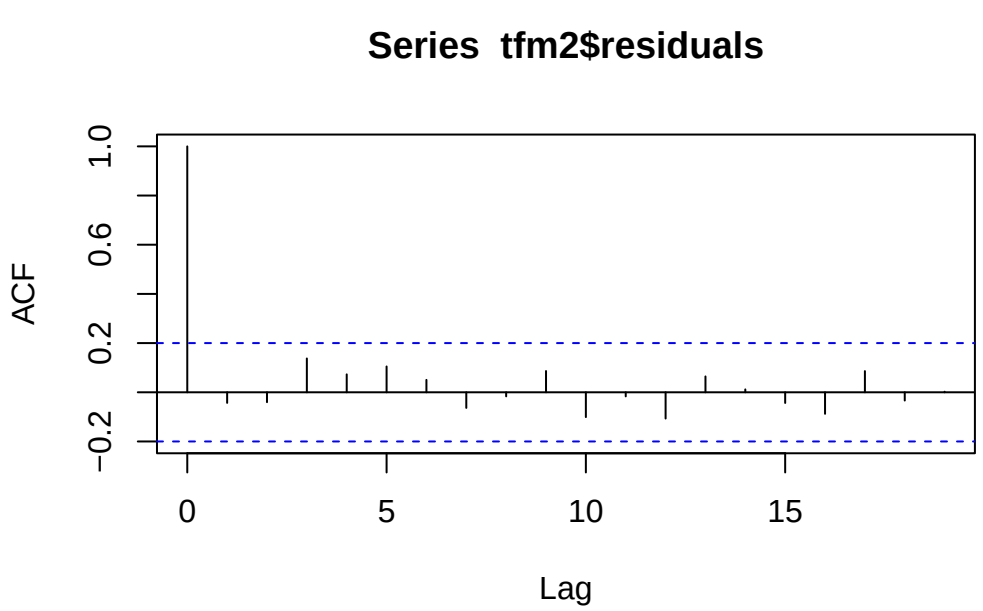
Sembra esserci leggera autocorrelazione dei residui, forse inserire un modello AR(2) per sbiancare aiuta

```
tfm2=MTS::tfm1(y,x,orderN=c(2,0,0), orderX=c(1,0,1))
```

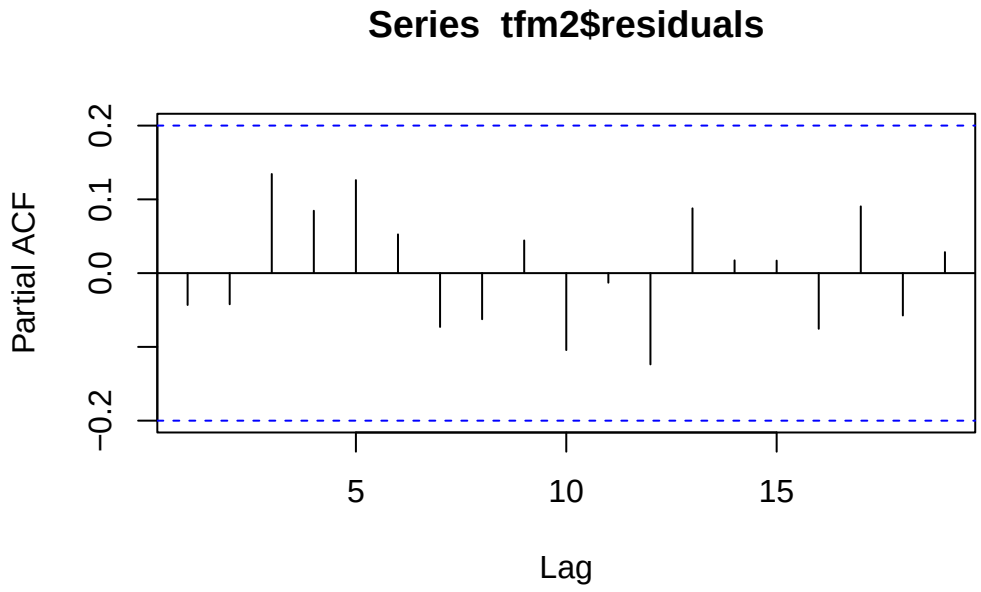
```
Delay:  1
```

```
Transfer function coefficients & s.e.:
in the order: constant, omega, and delta: 1 1 1
         [,1] [,2]   [,3]
v    -0.00565 2.53 -0.176
se.v  0.00256 0.34  0.137
ARMA order:
[1] 2 0 0
ARMA coefficients & s.e.:
           [,1]  [,2]
coef.arma 0.103 0.252
se.arma   0.106 0.106
```

```
acf(tfm2$residuals)
```




```
pacf(tfm2$residuals)
```



Infatti è cosi, non c'è correlazione tra i residui, possiamo dire di aver identificato un buon modello TFM.

Previsioni

Passiamo quindi alle previsioni, dove confronteremo tutti i modelli proposti fino ad ora oltre a modelli univariati del tipo ARIMA. Confronteremo quindi:

- VAR(1) e VAR(2), con investimenti come variabile target. Questo perchè essendo che PIL sembra granger-causare investimenti, dovremmo riuscire a prevedere meglio questi ultimi usando proprio il PIL
- modello univariato ARIMA per investimenti
- modello VECM

VAR

Iniziamo dal VAR(1)

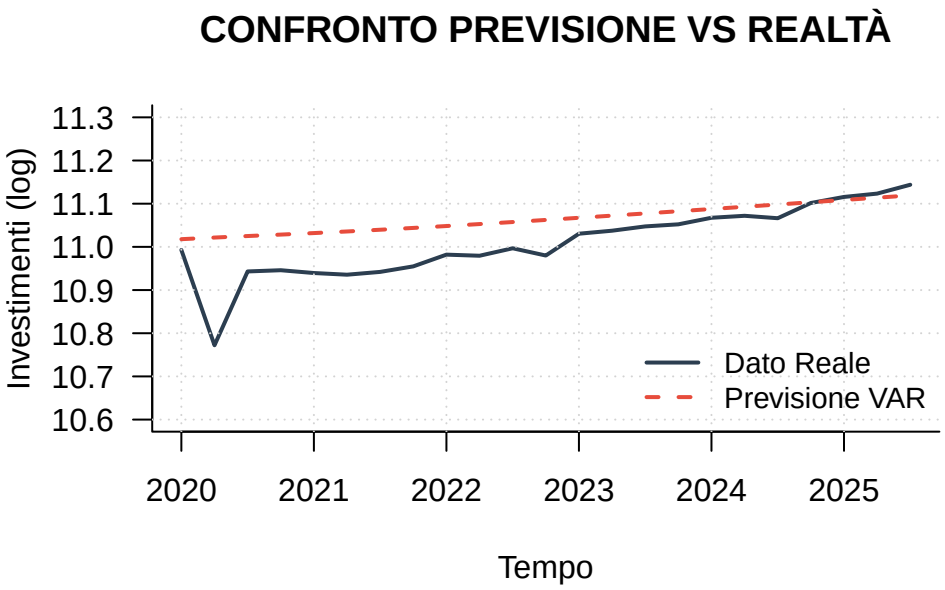
```
mod1=vars::VAR(dati_ok, p = 1, type = "const")

n_ahead=NROW(test)
prev=predict(mod1, n.ahead = n_ahead)
```

```r
fcst_inv=prev$fcst[["d_inv"]][, "fcst"]
ultimo_log_train = as.numeric(tail(train_log[, 2], 1))
log_serie_prevista = ultimo_log_train +
  cumsum(as.numeric(fcst_inv))

true_inv=log(test[, 2])


par(mar = c(5, 5, 4, 2))
plot(true_inv,
     ylim = c(10.6, 11.3),
     ylab = "Investimenti (log)",
     xlab = "Tempo",
     main = "CONFRONTO PREVISIONE VS REALTÀ",
     col = "#2c3e50",
     lwd = 2,
     bty = "l",
     las = 1)
grid(nx = NULL, ny = NULL, col = "lightgray", lty = "dotted")
lines(ts(log_serie_prevista, start = c(2020, 1), freq = 4),
      col = "#e74c3c",
      lwd = 2,
      lty = 2)
legend("bottomright",
       legend = c("Dato Reale", "Previsione VAR"),
       col = c("#2c3e50", "#e74c3c"),
       lwd = 2,
       lty = c(1, 2),
       bty = "n",
       cex = 0.9)
```




```
errori = true_inv - log_serie_prevista
mse1 = mean(errori^2)
rmse1 = sqrt(mse1)

# Vediamo i risultati
cat("MSE sul dataset di verifica:", mse1, "\n")
```

```
MSE sul dataset di verifica: 0.006074907
```

```
cat("RMSE sul dataset di verifica:", rmse1, "\n")
```

```
RMSE sul dataset di verifica: 0.07794169
```

Il modello ovviamente non riesce a prevedere lo shock covid, tuttavia i dati reali con il tempo si allineano con le previsioni, dimostrando discreta capacità predittiva. Vediamo ora con p=2

```
mod1=vars::VAR(dati_ok, p = 2, type = "const")

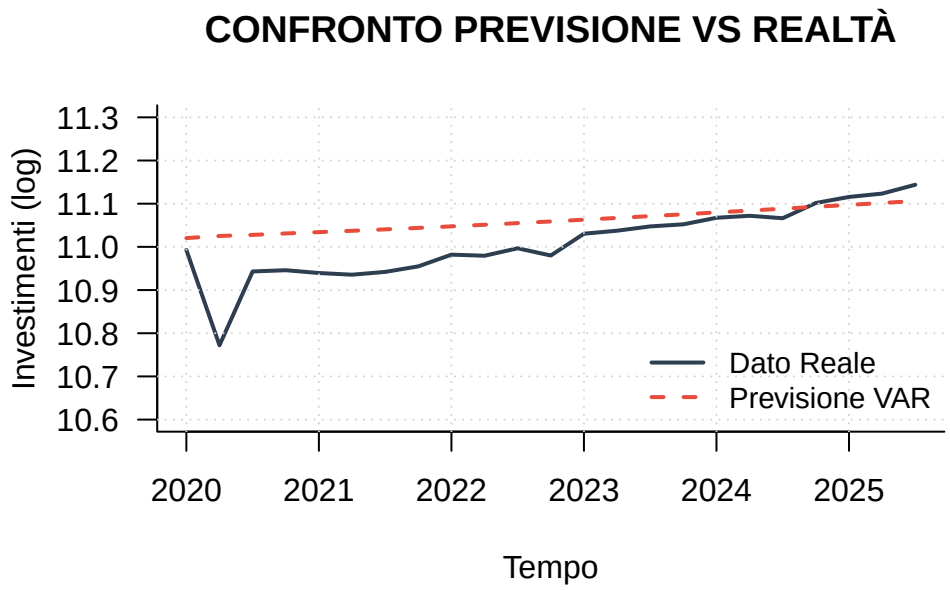
n_ahead=NROW(test)
prev=predict(mod1, n.ahead = n_ahead)


fcst_inv=prev$fcst[["d_inv"]][, "fcst"]
```

```r
ultimo_log_train = as.numeric(tail(train_log[, 2], 1))
log_serie_prevista = ultimo_log_train +
  cumsum(as.numeric(fcst_inv))

true_inv=log(test[, 2])


par(mar = c(5, 5, 4, 2))
plot(true_inv,
     ylim = c(10.6, 11.3),
     ylab = "Investimenti (log)",
     xlab = "Tempo",
     main = "CONFRONTO PREVISIONE VS REALTÀ",
     col = "#2c3e50",
     lwd = 2,
     bty = "l",
     las = 1)
grid(nx = NULL, ny = NULL, col = "lightgray", lty = "dotted")
lines(ts(log_serie_prevista, start = c(2020, 1), freq = 4),
      col = "#e74c3c",
      lwd = 2,
      lty = 2)
legend("bottomright",
       legend = c("Dato Reale", "Previsione VAR"),
       col = c("#2c3e50", "#e74c3c"),
       lwd = 2,
       lty = c(1, 2),
       bty = "n",
       cex = 0.9)
```




```
errori = true_inv - log_serie_prevista
mse2 = mean(errori^2)
rmse2 = sqrt(mse2)

# Vediamo i risultati
cat("MSE sul dataset di verifica:", mse2, "\n")
```

```
MSE sul dataset di verifica: 0.00614793
```

```
cat("RMSE sul dataset di verifica:", rmse2, "\n")
```

```
RMSE sul dataset di verifica: 0.07840874
```

La linea segue la precedente: possiamo dare le stesse conclusioni. Inoltre, l'errore di previsione si riduce, ma in modo irrisorio.

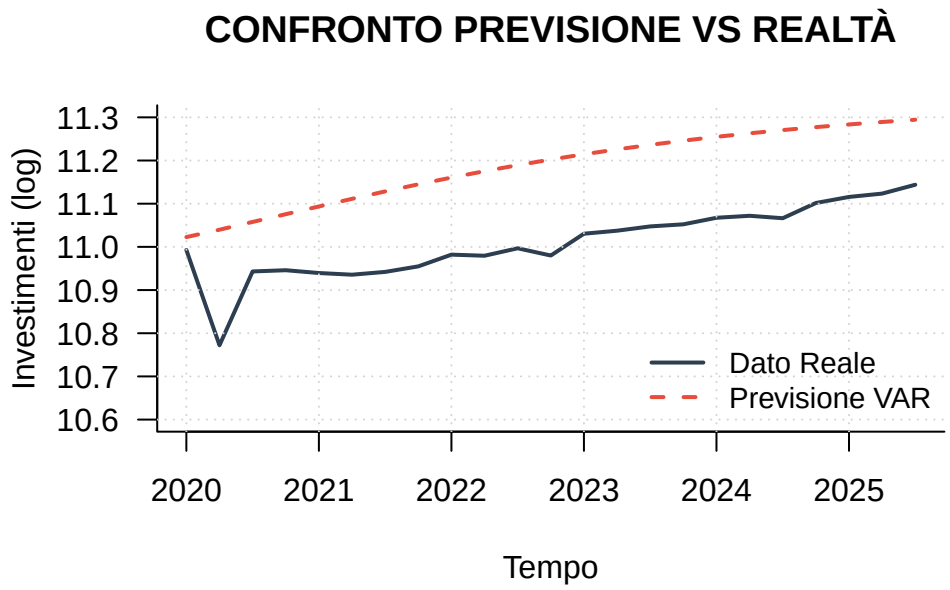
VECM

Vediamo invece per il caso VECM come funziona

```
modVAR=vec2var(vecm_jo, r = 3)
n_ahead=NROW(test)
prev=predict(modVAR, n.ahead = n_ahead)


fcst_inv=prev$fcst[["Inv"]][, "fcst"]
true_inv=log(test[, 2])


par(mar = c(5, 5, 4, 2))
plot(true_inv,
     ylim = c(10.6, 11.3),
     ylab = "Investimenti (log)",
     xlab = "Tempo",
     main = "CONFRONTO PREVISIONE VS REALTÀ",
     col = "#2c3e50",
     lwd = 2,
     bty = "l",
     las = 1)
grid(nx = NULL, ny = NULL, col = "lightgray", lty = "dotted")
lines(ts(fcst_inv,start = c(2020, 1), freq = 4),
      col = "#e74c3c",
      lwd = 2,
      lty = 2)
legend("bottomright",
       legend = c("Dato Reale", "Previsione VAR"),
       col = c("#2c3e50", "#e74c3c"),
       lwd = 2,
       lty = c(1, 2),
       bty = "n",
       cex = 0.9)
```




```
errori = true_inv - fcst_inv
mse3 = mean(errori^2)
rmse3 = sqrt(mse3)

# Vediamo i risultati
cat("MSE sul dataset di verifica:", mse3, "\n")
```

```
MSE sul dataset di verifica: 0.03260264
```

```
cat("RMSE sul dataset di verifica:", rmse3, "\n")
```

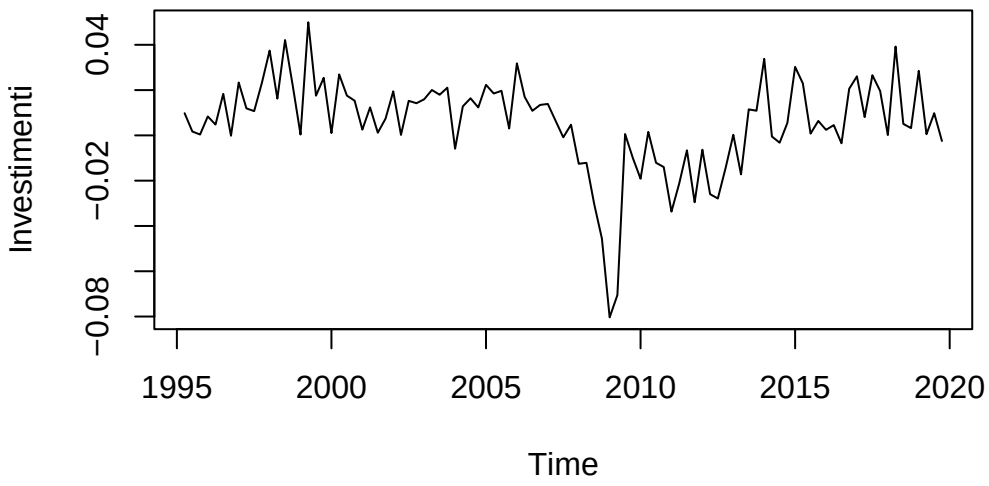
```
RMSE sul dataset di verifica: 0.180562
```

Il grafico mostra come le previsioni utilizzando il VECM peggiorino: sono molto più elevate rispetto ai dati reali. Questo viene confermato dall'errore di previsione, che aumenta rispetto ai modelli precedenti. Potrebbe proprio essere dato dal fatto che il COVID ha portato ad una rottura dell'equilibrio di cointegrazione.

Univariato

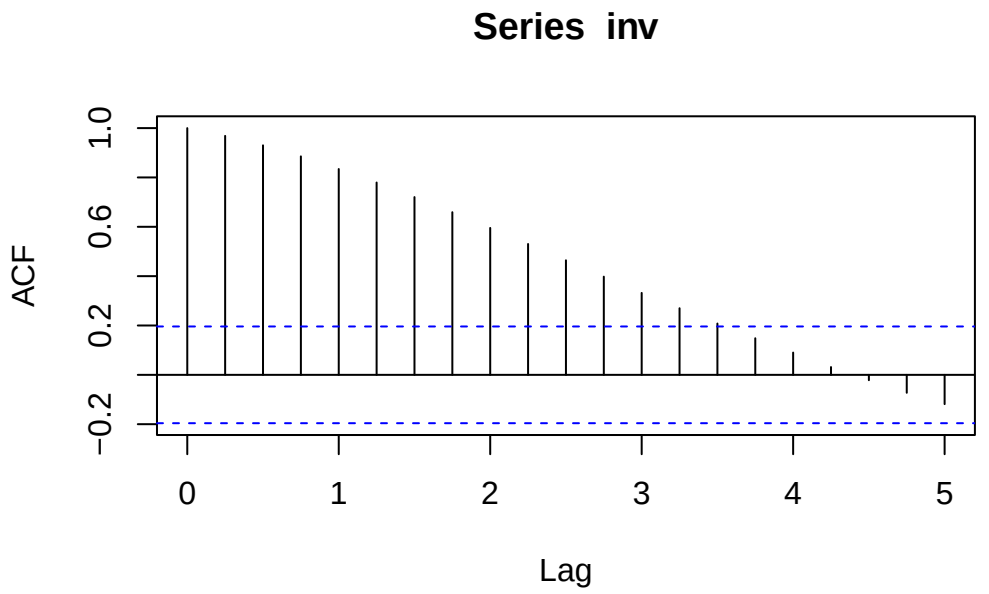
Ora, vogliamo vedere se i modelli multivariati sono utili per le previsioni rispetto ai modelli univariati, confrontiamo quindi le previsioni per un modello ARMA sulla serie differenziata dei logaritmi degli investimenti.

```
plot.ts(dati_ok[,2], ylab="Investimenti")
```

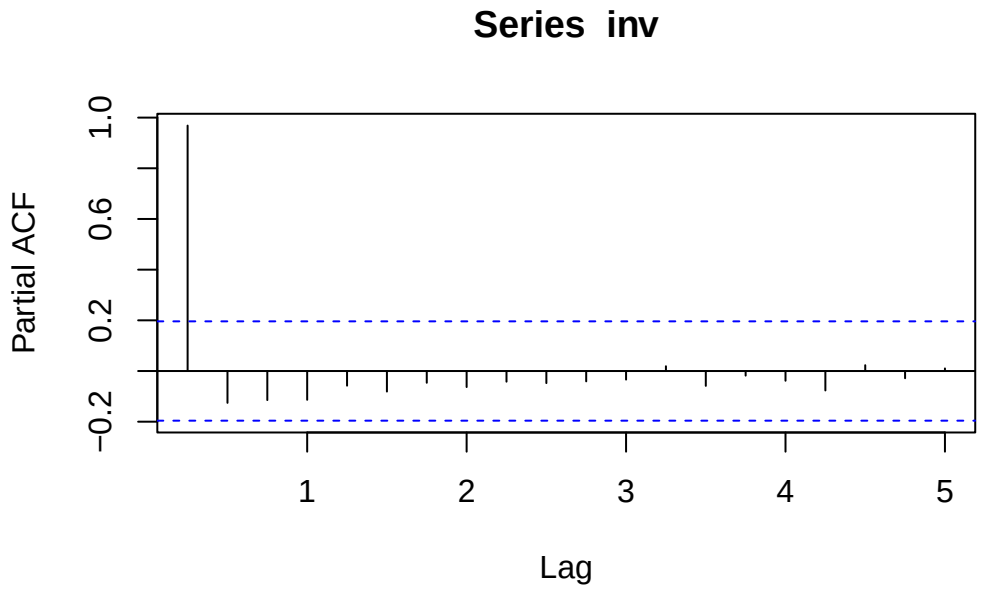



```
inv=train_log[,2]

acf(inv)
```




```
pacf(inv)
```




```
#ar(1) o 2?
```

```
mod_inv1=Arima(inv, order=c(1,1,0),
               include.mean = T,include.drift = T)
mod_inv1
```

```
Series: inv
ARIMA(1,1,0) with drift

Coefficients:
       ar1   drift
      0.59  0.0055
s.e.  0.08  0.0040

sigma^2 = 0.0002766:  log likelihood = 266.08
AIC=-526.16   AICc=-525.91   BIC=-518.38
```

```
mod_inv2=Arima(inv, order=c(2,1,0),
               include.mean = T,include.drift = T)
mod_inv2
```

```
Series: inv
ARIMA(2,1,0) with drift
```

```
Coefficients:
         ar1     ar2   drift
      0.4217  0.2794  0.0054
s.e.  0.0957  0.0956  0.0051

sigma^2 = 0.000257:  log likelihood = 270.16
AIC=-532.32   AICc=-531.9   BIC=-521.94
```

```
mod_inv3=Arima(inv, order=c(3,1,0),
               include.mean = T,include.drift = T)
mod_inv3#no
```

```
Series: inv
ARIMA(3,1,0) with drift

Coefficients:
         ar1     ar2     ar3   drift
      0.3739  0.2073  0.1665  0.0054
s.e.  0.0985  0.1033  0.0979  0.0059

sigma^2 = 0.0002522:  log likelihood = 271.58
AIC=-533.17   AICc=-532.52   BIC=-520.19
```

```
mod_inv4=Arima(inv, order=c(2,1,1),
               include.mean = T,include.drift = T)
mod_inv4#no
```

```
Series: inv
ARIMA(2,1,1) with drift

Coefficients:
         ar1     ar2      ma1   drift
      0.8105  0.0552  -0.4392  0.0054
s.e.  0.2559  0.1889   0.2407  0.0062

sigma^2 = 0.0002533:  log likelihood = 271.37
AIC=-532.75   AICc=-532.1   BIC=-519.77
```

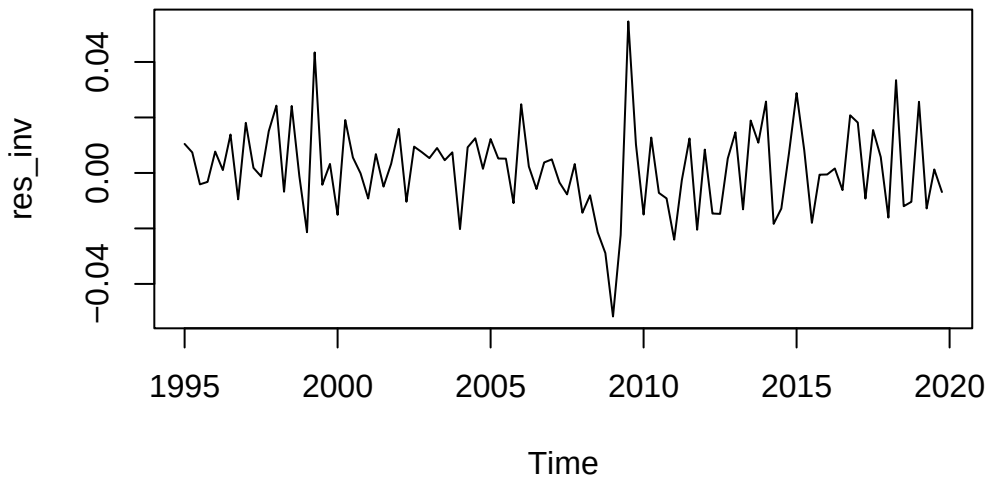
```
mod_inv5=Arima(inv, order=c(2,1,0),
               include.mean = F,include.drift = F)
mod_inv5
```

```
Series: inv
ARIMA(2,1,0)

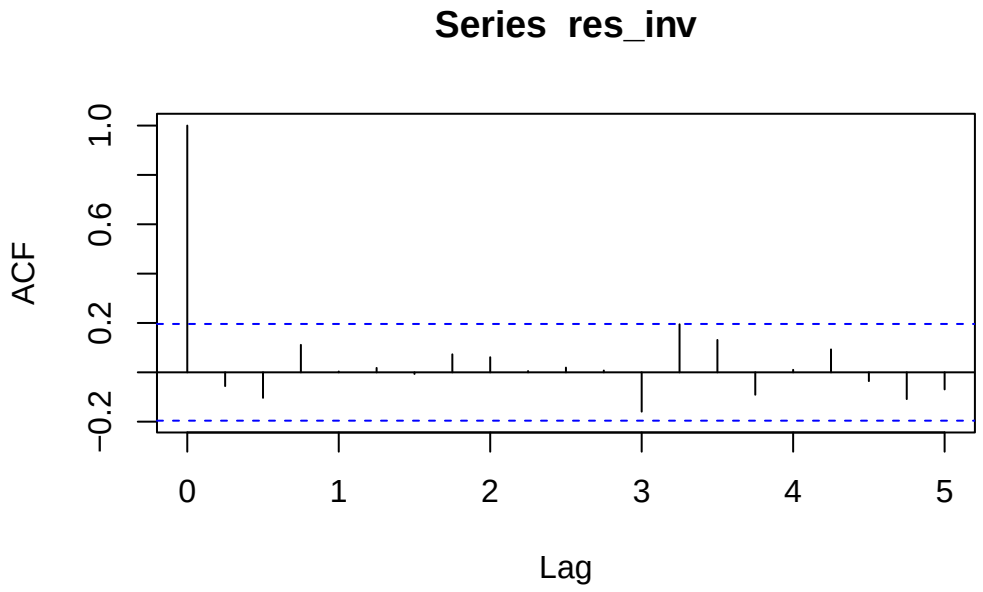
Coefficients:
         ar1     ar2
      0.4342  0.2912
s.e.  0.0953  0.0953

sigma^2 = 0.0002569:  log likelihood = 269.64
AIC=-533.29   AICc=-533.04   BIC=-525.5
```

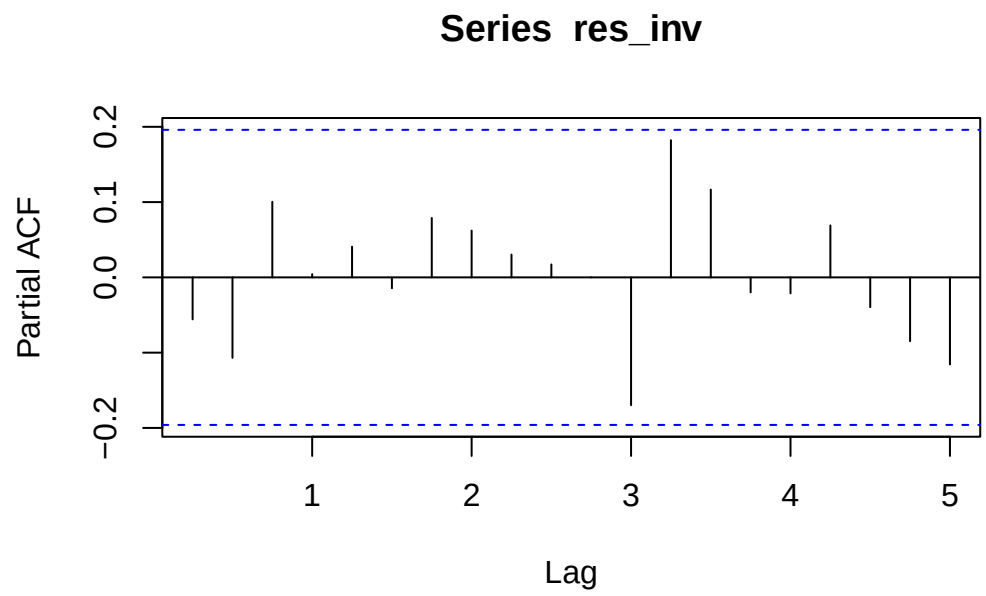
```
res_inv=mod_inv5$residuals
plot(res_inv)
```




```
acf(res_inv)
```



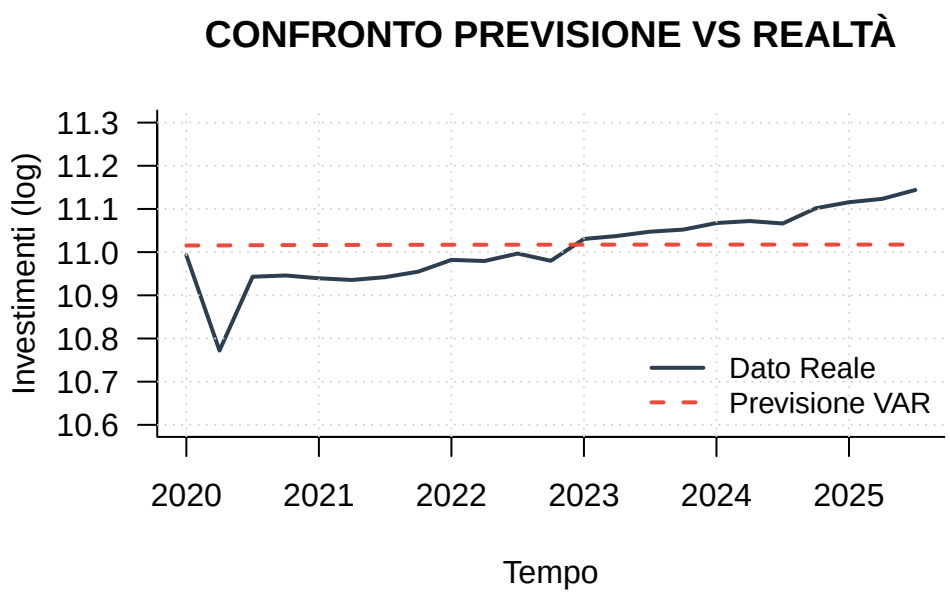

```
pacf(res_inv)
```




```
#nessuna correlazione seriale per i residui
```

```
library(forecast)
previsioni=as.numeric(forecast(mod_inv5,
                               h=n_ahead)$mean)
true_inv=log(test[, 2])
```

```r
par(mar = c(5, 5, 4, 2))
plot(true_inv,
     ylim = c(10.6, 11.3),
     ylab = "Investimenti (log)",
     xlab = "Tempo",
     main = "CONFRONTO PREVISIONE VS REALTÀ",
     col = "#2c3e50",
     lwd = 2,
     bty = "l",
     las = 1)
grid(nx = NULL, ny = NULL, col = "lightgray", lty = "dotted")
lines(ts(previsioni,start = c(2020, 1), freq = 4),
      col = "#e74c3c",
      lwd = 2,
      lty = 2)
legend("bottomright",
       legend = c("Dato Reale", "Previsione VAR"),
       col = c("#2c3e50", "#e74c3c"),
       lwd = 2,
       lty = c(1, 2),
       bty = "n",
       cex = 0.9)
```



```r
errori = true_inv - previsioni
mse4 = mean(errori^2)
rmse4 = sqrt(mse4)

# Vediamo i risultati
cat("MSE sul dataset di verifica:", mse4, "\n")
```

```
MSE sul dataset di verifica: 0.006562783
```

```r
cat("RMSE sul dataset di verifica:", rmse4, "\n")
```

```
RMSE sul dataset di verifica: 0.081011
```

Sia dal grafico che dall'errore di previsione che aumenta, possiamo concludere come riusciamo a prevedere meglio usando i modelli multivariati, significa che riusciamo a prevedere meglio gli investimenti usando i valori passati anche di altre variabili, quali PIL e tassi di interesse.

Dal grafico vediamo che non si riesce a seguire il trend crescente ma viene predetta una linea dritta.

Conclusioni

Dopo aver svolto le nostre analisi possiamo trarre diverse conclusioni.

Innanzitutto, le analisi con i modelli VAR riescono a dirci come si comportano tra di loro le variabili del sistema, ad esempio siamo riusciti ad estrarre il ruolo esogeno delle variabili PIL e tassi a lungo termine, oppure siamo riusciti a capire come con dati di alcune variabili si riesca a prevedere in maniera più efficiente i valori futuri di altre. Questo è stato confermato ulteriormente dal confronto delle previsioni.

Si è inoltre confermata la relazione di cointegrazione tra le variabili, e si è riuscito a confermare il ruolo esogeno di PIL e tassi a lungo termine, oltre a quello fortemente endogeno dei tassi a breve termine.

Il modello a funzione di trasferimento bivariato, con PIL in ingresso e investimenti in uscita, descrive bene la relazione: l'effetto del PIL sugli investimenti con ritardo di un trimestre è positivo e significativo, i residui sono incorrelati e il risultato è coerente con il VAR. Questo modello non è però entrato nel confronto delle previsioni.

Uso IA

L'intelligenza artificiale, per la produzione del documento, è stata utilizzata per i seguenti scopi:

- reperimento dati: sia per capire quali sarebbero potute essere variabili interessanti, sia per trovare un sito di riferimento da cui scaricarle
- codice: sono presenti pezzi di codice non presenti nei laboratori, su tutti alcuni grafici, come quelli delle previsioni, che sono stati perfezionati per l'occasione
- commenti: è stata usata l'intelligenza artificiale per confermare la correttezza dei commenti riguardo a output complessi (ad esempio IRF e FEVD)
- immagine presente nel paragrafo relativo alla causalità di Granger: quella dove si vedono le varie relazioni di Granger tra le variabili
- correzione di errori grammaticali/di sintassi
- motivazioni economiche: è stata utilizzata per cercare aiuto riguardo la teoria economica e le ragioni economiche dei comportamenti della serie